

## 二〇二五届毕业论文

# 考虑交通流影响下的电动车充电物流配送 送路径规划研究

学    院：未来交通学院

专    业：车辆工程

姓    名：王子言

学    号：2021901252

指导教师：王澍

完成时间：2025.5.25

二〇二五年五月

## 摘要

随着电动汽车的蓬勃发展，在物流行业中越来越多的电动汽车参与货物的运输与配送，因此如何进行合理路径规划，节约配送成本对于物流配送企业来说至为关键，由于传统的电动汽车路径规划研究大多忽略了实际交通流量对于行驶车速的影响，因此本研究旨在建立考虑交通流量影响下的电动车辆路径规划模型，并在此基础上针对不同的充换电策略对于配送成本的影响进行进一步探究。

本文首先针对电动车辆路径规划问题建立了数学模型，首先建立交通路网模型，以刻画道路的交通状态，然后建立了考虑交通流量因素的电动车辆能耗模型，为后续建立目标方程以及实验中设计求解算法提供理论依据。接着，考虑充换电策略建立了数学模型，为后续进一步探究充换电策略提供了理论基础，最后设计出路径规划优化的目标方程，为建立求解算法提供理论依据。

为了引入交通流量对于车速的实际影响，考虑到实际进行路径规划的过程中，未来的交通流量无法直接获取，需采取一定的预测策略进行近似拟合，传统的预测算法有直接采用历史数据拟合、利用历史数据的平均值拟合，本文中采用深度学习模型，引入交通流量预测方面的相关研究成果，搭建 CEEMD-LSTM 模型有效解决了无法获取有效的交通流量数据的问题。

最后，依据前面建立的数学模型，设计遗传算法并根据计算结果进行了相应的算法改进，在实验算例方面分别选取了开源数据集中的标准数据集。经过实验，发现考虑交通流量影响后，路径规划成本相比于传统模型提高了约 20.4 这意味着交通流量对于电动车辆路径规划影响不可忽视。

在此基础上，本文探究还了不同充换电策略在不同成本场景下的表现，最后得出结论：当换电单位电量成本大于充电单位电量成本 10 倍以上时，采取充电策略成本更低；当换电单位电量成本小于充电单位电量成本 10 倍以上时，采取换电策略成本更低；当客户惩罚成本较高时，80%充电策略相比于 100%充电策略成本降低了 8.4%。

**关键词：**电动车路径规划，遗传算法，交通流量预测，深度学习

## ABSTRACT

With the thriving development of electric vehicles, more and more of them are engaged in goods transportation and distribution in the logistics industry. Thus, planning reasonable routes to cut distribution costs is of great significance for logistics enterprises. However, traditional electric vehicle route planning research often overlooks the impact of actual traffic flow on driving speed. This study aims to establish a route - planning model for electric vehicles considering traffic flow and further explore how different charging and battery - swapping strategies affect distribution costs.

This paper constructs a mathematical model for the electric vehicle route - planning problem. First, a traffic network model is established to describe road traffic conditions, and then an electric vehicle energy consumption model considering traffic flow is developed, which provides a theoretical basis for establishing the objective equation and designing the solution algorithm in experiments. Next, a model considering charging and battery - swapping strategies is created, laying a foundation for further research on these strategies. Finally, an optimized objective equation for route planning is designed to support the establishment of the solution algorithm.

Since future traffic flow cannot be directly obtained during route planning, prediction strategies are required. Instead of traditional methods like using historical data directly or its average value for fitting, this paper uses a deep - learning - based CEEMD - LSTM model. This model, developed by incorporating relevant traffic flow prediction research, effectively addresses the issue of obtaining reliable traffic flow data.

Based on the established mathematical model, a genetic algorithm is designed and refined according to calculation results. Standard datasets from open - source sources are used for experiments. The results show that considering traffic flow increases the route - planning cost by about 20.4% compared to traditional models, highlighting its non - negligible impact.

Moreover, this paper explores the performance of different charging and battery - swapping strategies in various cost scenarios. It concludes that when the unit - electricity - cost of battery - swapping is over 10 times that of charging or less than one - tenth, the charging strategy is more cost - effective. When the customer penalty cost is high, the 80% charging strategy reduces costs by 8.4% compared to the 100% charging strategy.

**KEYWORDS:** Electric Vehicle Routing Problem, Genetic Algorithm, Traffic Flow Prediction, Deep Learn

# 目 录

目 录.....	1
第一章 绪论.....	3
1.1 研究背景及研究意义.....	3
1.1.1 研究背景.....	3
1.1.2 研究意义.....	3
1.2 国内外研究现状.....	4
1.2.1 电动车辆路径规划问题.....	4
1.2.2 交通流量预测模型.....	5
1.2.3 研究现状总结.....	6
1.3 研究内容及组织.....	6
1.3.1 研究内容.....	6
1.3.2 主要创新点.....	错误!未定义书签。
1.4 本章小结.....	7
第二章 电动车辆路径规划问题数学模型.....	8
2.1 考虑动态交通路网状态的电动车能耗模型构建.....	8
2.1.1 交通路网建模.....	8
2.1.2 电动车能耗模型.....	9
2.2 考虑充换电策略的电动车路径规划模型构建.....	11
2.2.1 充换电策略模型.....	11
2.2.2 目标函数建模.....	13
2.2.3 约束条件与问题假设.....	14
2.3 本章小结.....	15
第三章 考虑交通流预测的路径规划.....	16
3.1 相关理论基础.....	16
3.1.1 长短时记忆神经网络.....	16
3.1.3 经验模态分解（EMD）.....	19
3.2 道路交通预测模型介绍.....	21
3.3 交通流量预测算法实验.....	22
3.3.1 实验数据.....	22
3.3.2 CEEMD 技术数据处理.....	23
3.3.3 实验结果分析.....	24
3.4 本章小结.....	26

第四章 算法设计与实验分析.....	27
4.1 遗传算法设计 .....	27
4.1.1 路径规划类问题求解算法.....	27
4.1.2 遗传算法设计.....	28
4.2 实验对比与分析 .....	30
4.2.1 实验数据准备.....	30
4.2.2 考虑精英保留策略的改进遗传算法实验分析.....	31
4.2.3 考虑交通流量下的电动车物流配送遗传算法实验分析.....	34
4.2.4 电动车充换电物流配送策略的遗传算法实验分析.....	35
4.3 本章小结 .....	39
第五章 总结与展望.....	40
5.1 总结 .....	40
5.2 展望 .....	40
参考文献.....	41
附录.....	45

# 第一章 绪论

## 1.1 研究背景及研究意义

### 1.1.1 研究背景

物流行业是一个支撑现代经济发展的重要产业，随着中国电商市场的不断扩大，物流行业市场规模也在不断增长。根据统计的数据，2019 年全社会物流总额达到 298 万亿元，同比增长 5.9%，2023 年，中国物流行业的市场规模已经达到了 5000 亿元人民币，这一市场规模的不断扩大，为物流企业的发展提供了广阔的空间。2018 年 10 月，国务院颁布《关于加快推进物流信息化和智能化发展的指导意见》该政策明确提出要加快推进物流信息化和智能化发展，推动物流行业向智能物流转型，提高物流效率和服务水平。物流车辆路径规划问题旨在利用现代技术找到最优化的物流配送路径，从而提高物流效率降低配送成本。

据统计，2022 年，我国新能源物流车产销量分别为 25.8 万辆和 23.59 万辆，较上年同期分别增长 95.6%和 79.8%。相比与传统汽车，新能源汽车凭借其低碳环保的优势在物流行业有望逐步取代传统燃油车成为主要的物流运输交通工具。而当前纯电动物流车正处于发展阶段，电池和充电技术尚未成熟，面临着里程焦虑问题，这意味着新能源物流车在运送过程中必须前往充电站充电。国内已有学者针对新能源汽车充电问题对传统的车辆路径规划问题进行变体，但关于新能源汽车的路径规划方案的研究大多没有考虑到时变性因素，为使新能源物流车路径规划方案更加现实、高效，需要考虑交通量时变性因素对于路径规划的影响。

### 1.1.2 研究意义

#### （1）理论意义

车辆路径规划问题（Vehicle Routine Problem,VRP），在 1959 年被 Dantzing 和 Ramser 两位学者首次提出<sup>[1]</sup>。经典的车辆路径规划问题可以被描述为：物流车队从某一物流中心出发，在保证所有客户被满足的前提和一定的约束条件下，找到最短的车辆配送路径。为了使研究更加贴合实际应用，国内外学者在此基础上对 VRP 问题进行拓展研究，在经典的 VRP 问题基础上增加新的约束条件和成本，使其更加贴合物流行业的现实需求。例如：学者们在经典的 VRP 问题的基础上增加时间窗约束，就形成了 VRPTW 问题；学者们在经典的 VRP 问题的基础上考虑能源消耗和碳排放成本，就形成了 GVRP 问题等。

本研究的学术意义在于，在考虑新能源汽车充电问题的基础上，考虑到道路交通流对于车辆行驶速度的影响。在关于时变路网的研究时，一般方法为利用历史数据估计每条道路的通行时间，并近似做出每条道路通行时间与一天 24 小时时刻相关的时间依赖函数，来刻画路网的时变特性。交通量预测和电动车辆路径规划问题通常被作为两个独立的课题进行研究，本研究将两个课题结合旨在提出一种基于深度学习的用于预测道路交通量的方法，并将其应用于纯电动物流车路径规划方案的研究中，为其他学者提供研究思路

#### （2）现实意义

电商的迅速发展，促进了城市的物流运输，人们对于物流运输需求也越来越大，而车辆的配送决策往往决定了物流企业的运输效率，合理的配送路径规划不仅可以提高物流企业服务质量，提高城市人民生活水平，而且可以减少交通拥堵，降低能源消耗和碳排放量，促进

城市可持续发展。

对于物流企业而言,一般的配送路径规划决策未考虑道路交通流情况,则可能会出现某路段实际距离很短,但由于该路段实际车速过慢从而导致客户未能按照预期规划的时间窗内被服务的情况,进而导致之前的路径规划决策失效。因此,本研究对于物流企业进行物流配送决策具有现实指导意义,可以为其减少物流配送的时间成本,提高其服务效率。对于环境保护而言,本研究可以降低物流运输过程中的能源消耗和碳排放量。

## 1.2 国内外研究现状

### 1.2.1 电动车辆路径规划问题

当前国内已有部分学者考虑到路网时变性对于 EVRP 规划的影响。张博等<sup>[2]</sup>学者考虑到电动车排队充电时间的时序特性,以电动车行驶成本、充电成本和车辆费用为目标函数建立混合整数规划模型。温廷新等<sup>[3]</sup>学者假设时变路网数据信息已从交通部门获取,并考虑充电过程成本和不同温层货损成本纳入目标函数。王玖河等<sup>[4]</sup>学者考虑了交通路网的时变特性对电动车实际配送过程中的影响,并应用 AP 聚类算法对配送区域进行划分,提高配送效率。陈秋实等<sup>[5]</sup>学者考虑到交通流对于电动车能耗的影响,建立了基于能耗的最短路径算法,并建立了基于 GCN 的交通流预测模型,并将两者结合进行路径规划。李可昕<sup>[6]</sup>以 M 生鲜肉类公司为研究对象,将车辆充电时的费用,充电时冷鲜货损以及车辆预冷成本纳入目标函数,在考虑时变路网特性的基础上采用多温共配的方式进行物流配送。

当前国内对于单独的考虑时变路网的车辆路径规划问题以及单独的电动车充电问题的相关研究较为充分。胡婉婉<sup>[7]</sup>提出一种结合路段实时速度和路段时变速度相结合的路径通行时间计算方法。同时引入可靠程度降低通行时间估计误差的影响。胡凯<sup>[8]</sup>为反映城市路网的时变特性,采用了基于时间段划分的车辆行驶时间计算方法并着重关注乘客体验和碳排放成本。赵佳欣等<sup>[9]</sup>学者综合考虑了路段和时段对车速的影响、不同客户额去送货需求及客户关系、多种车辆的载重约束,建立时变路网多车型去送货模型。刘文琪<sup>[10]</sup>在采用分段函数表现车速随时间变化的基础上考虑车辆行驶加速度。范厚明等<sup>[11,12]</sup>采用多个三角函数关系式及多项式表现车速随时间连续变化关系。针对电动车路径规划的研究,雷宇健等<sup>[13]</sup>学者考虑充电模式成本低但时间较长,换电模式成本较高但换电时间很短,并建立了一种兼顾两者优点的补电模式。邢思远<sup>[14]</sup>研究了行驶速度与载重的非线性能量消耗模型,对弧段速度优化明显减少了能量消耗。

对于路网的时变性因素对于路径规划问题的影响,国外学者进行了广泛的研究。Kok 等<sup>[15]</sup>考虑交通拥堵情况以及驾驶时间规则等因素,引入时变网络模型,建立以驾驶时间最短为目标函数的路径优化模型。Tas 等<sup>[16]</sup>考虑了具有软时间窗和随机出行时间的车辆路径规划问题。Zheng<sup>[17]</sup>建立了基于时变交通流的多模糊时间窗车辆路径规划问题模型。Montoya 等<sup>[18]</sup>人研究发现电动车充电时间在不同阶段有着不同的充电速率,并非呈线性关系,因此研究了非线性充电下的电动车路径规划问题,提高了充电时间的真实度。Schneider 等<sup>[19]</sup>将线性充电函数近似估计充电时间,假设充电量是充电时间的线性函数,充电时间根据车辆到站电量水平与充电速率决定。

对于电动车物流配送路径规划问题,国外已有大量学者进行了相关研究。Keisuke<sup>[20]</sup>在论文中主要研究了电动车和柴油车混合使用的车队的配送路径问题。在研究中,Keisuke考虑了道路坡度、车速和加速度等因素的数学模型,确定了所需的电动车和柴油车数量。Schiffer M.<sup>[21]</sup>等学者考虑不同的充电策略对于配送成本的影响。Çatay Bülent 等<sup>[22]</sup>学者则提出了带时间窗和移动充电站的电动汽车路径问题。Comert Serap Ercan 等<sup>[23]</sup>学者考虑到在实际应用中车辆的路径规划的优化目标往往是多个目标而不是一个目标。因此,同时对五个相互冲突的目标函数进行优化。Verma<sup>[24]</sup>研究了快充、慢充和换电等不同方式的 EVRP。Hiermann 等<sup>[25]</sup>研究了混合车型和不同车队规模的 EVRP。Keskin 等<sup>[26]</sup>用排队论处理充电桩数量有限及非线性分段充电率的 EVRP。Keskin<sup>[27]</sup>引入了不完全充电策略,通过合理规划每次充电的电量来改变充电时间,从而满足时间窗约束。Desaulniers 等<sup>[28]</sup>使用分支定价求解了一次充电、多次充电、满充和部分充电等不同策略的 EVRP 方案;Felipe 等<sup>[29]</sup>使用局部搜索和模拟退火算法求解部分充电的 EVRP。Shao 等<sup>[30]</sup>构建了混合遗传算法求解 EVRP。Cortés-Murcia 等<sup>[31]</sup>构造了局部迭代搜索元启发式框架和变邻域下降算法求解部分充电的 EVRP,提出合理利用充电时间,如通过步行方式配送距充电站较近的客户。Macrina 等<sup>[32]</sup>考虑了加速减速制动阶段的能耗问题,使用大邻域搜索算法求解。Kancharla 等<sup>[33,34]</sup>考虑载重与耗电率之间的线性关系并构建了能耗最小为目标的数学模型,提出了带非线性充电和负载相关放电的 EVRP。

### 1.2.2 交通流量预测模型

当前国内围绕交通流预测问题的研究大致可分为两类:第一类是基于统计分析方法的模型,第二类是基于数据驱动智能算法的预测模型。

国内基于统计模型的方法有差分整合移动平均自回归<sup>[35]</sup>、支持向量回归<sup>[36]</sup>、卡尔曼滤波<sup>[37]</sup>等。这类方法虽然计算量小,但短时交通流具有非线性等特点,这类方法在预测准确性方面并不高,无法满足对复杂场景的预测的需求。近年来,国内较多学者利用历史数据结合基于深度学习建立的智能预测模型,预测更加准确。

叶得学<sup>[38]</sup>学者建立 ISSA-SVR 模型对短期交通流进行预测,利用支持向量回归模型泛化能力强,训练效率高的特点,并针对模型中的惩罚因子和核函数参数的选择建立了混合多策略改进麻雀搜索算法(HMSSSA)。同时引入反向学习策略从而提高初始生成解的质量,引入蝴蝶觅食算法(BOA)改善算法收敛速度过快,缺乏解的多样性的缺点。黄艳国等<sup>[39]</sup>学者,将改进的花朵授粉启发式算法与 BP 神经网络模型结合起来进行短期交通流预测。利用改进花朵算法寻找 BP 神经网络最优初始权值和阈值。张萌等<sup>[40]</sup>学者基于 LSTM 神经网络模型对短期交通量进行预测,重点研究了时序学习能力优秀的长短时记忆神经网络预测算法,分别在不同的时间粒度下建立了模型分别进行训练、验证、和预测实验。并对交通量序列应用不同的聚类算法进行聚类处理,从而提高预测精度。邹正标等<sup>[41]</sup>学者考虑到交通流的空间相关性与时间相关性之间的相互影响,采用图卷积网络对不进行动态建模,并构建了一个基于注意力机制的双向门控循环单元结构。曹威等<sup>[42]</sup>学者利用 Transformer 模型中的自注意力机制,建立交通流长期以来关系的模型,该模型可以同时捕捉时空信息和路网结构信息。



Meng 等<sup>[43]</sup>学者提出了一种基于深度学习的信号控制精细动态交通图(ScR-DTG)模型,以进行对交通网络的交通量预测。Hu 等<sup>[24]</sup>学者提出了一种新的交通量预测方法,该方法将 Butterworth 滤波器、卷积神经网络和长短期记忆网络(BWCL)相结合,有效提高了预测的准确性。Cao H<sup>[44]</sup>利用偏置值确定三层 BP 神经网络结构,并使用滚动预测的方法对短期交通量进行预测,验证模型的收敛性较好。R Tian<sup>[45]</sup>针对现有交通流速度模型数据集单一、模型单一的问题,提出了时间序列与 BP 神经网络结合的预测模型。Lin Y 等<sup>[46]</sup>学者结合收费站交通流数据的序列特征和时空特征提出了一种基于长短期记忆网络的交通流预测模型。Reza S<sup>[47]</sup>提出了多注意力机制的 Transformer 交通预测模型。Yan 等<sup>[48]</sup>提出了一种可以不同层学习不同特征,然后分层融合的 Transformer 模型。Xu 等<sup>[49]</sup>提出了一种新的基于时空的 Transformer 框架 STTN。

### 1.2.3 研究现状总结

针对电动物流配送车辆的研究,当前大多数学者针对其充/换电策略,电动汽车能耗等方面展开研究,但是少有学者考虑时变路网交通网络对电动汽车能耗以及配送成本的影响。针对交通流量预测模型,当前大多数学者采用时空图卷积神经网络以及近年来十分热门的 Transformer 注意力模型对未来交通流量进行预测。

## 1.3 研究内容及组织

### 1.3.1 研究内容

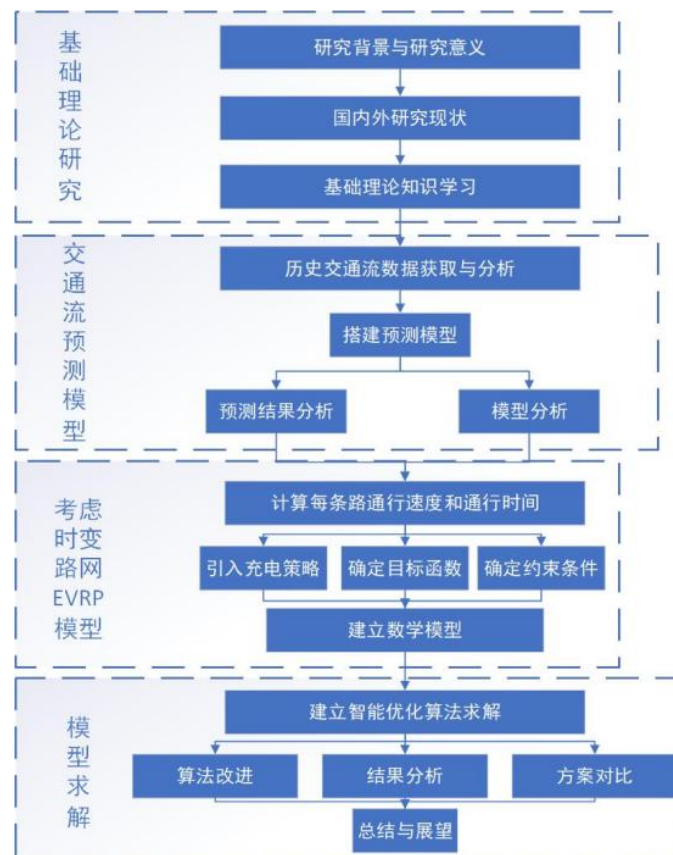


图 1.1 研究流程图

本课题的研究内容分为四个部分：基础理论研究、建立考虑时变路网的电动车路径规划模型、建立智能优化算法求解。如上图（图 1）所展示本课题研究内容。

首先通过文献阅读，明确课题的研究背景和研究意义，了解国内外近五年的研究方向。并进行理论知识的学习，包括了解并掌握 MATLAB 编程、Python 编程、离散数学、交通流理论、深度学习、智能优化算法等相关知识。

然后，通过理论知识学习，确定一种交通量预测方法，并搭建交通预测模型。获取某地交通历史数据作为示例，利用该数据集对模型进行训练并得到对未来某日交通预测结果，对结果准确性进行验证并与其他学者的预测结果进行对比分析，并依据分析结论对预测模型进行改进。

接着，将预测得到的道路交通量信息，依据交通流理论计算道路通行时间，和道路车辆行驶速度，同时引入电动物流车在充电站的充电策略，并确定目标方程和模型的约束条件用数学语言进行表达。

选择一种智能优化算法如遗传算法，对前面建立的数学模型进行编程计算求解。依据求解结果对算法进行分析改进，最后对得到的规划方案进行对比分析。

## 1.4 本章小结

本章我们首先阐述了本课题的研究背景、研究意义，针对电动车辆路径优化、和交通流量预测两大领域分别进行了国内外研究现状的说明，最后提出创新点：本研究将探究考虑交通流量因素对于路径规划的影响，并研究不同充换电策略在不同应用场景下的具体表现，为其他相关研究提供依据。

## 第二章 电动车辆路径规划问题数学模型

物流公司在进行电动车辆配送路径规划时,常常需要考虑每条道路的实际交通状况以进行合理的规划。同时,由于电动车辆存在里程焦虑的问题,在物流配送过程中,常常需要进行电量补充,充换电策略以及何时进行电量补充等因素将极大影响配送的效率和成本。本章将考虑道路交通情况,同时考虑充换电成本以及客户时间窗成本建立电动车辆物流配送数学模型。

### 2.1 考虑动态交通路网状态的电动车能耗模型构建

由于电动物流车辆在实际配送行驶过程中,其速度受到该道路交通流实际情况的限制。显然,当交通流量直接影响了配送车辆的行驶速度,进而影响配送车辆在行驶过程的能耗,因此本节将构建数学模型描述电动车辆能耗与动态路网交通状况的关系。

#### 2.1.1 交通路网建模

(1) 交通路网模型




图 2.1 交通路网异构图

如下图所示,为交通路网异构图示意图,其中  $s_i$  表示电动物流车辆配送过程中的每个目的地点,而  $q_{ij}$  表示相邻两地点之间的交通流量的大小。利用图论的方法构建如下所示的数学模型:

$$\begin{cases} G^T = (S, E, Q) \\ S = \{s_i | i = 1, 2, 3, \dots, n\} \\ E = \{s_{ij} | s_i \in S, s_j \in S, i \neq j\} \\ Q = \{q_{ij} | s_{ij} \in E, q_{ij} = f(t)\} \end{cases} \quad (1)$$

式中  $G^T$  表示交通路网,其包括三个集合,分别为  $S$  表示所有节点的集合,  $E$  表示所有路段集合,  $Q$  表示所有路段的交通流量的集合,其中  $q_{ij}$  表示从节点  $i$  到节点  $j$  之间的交通路段中交通量,其值是一个与时间相关的分段函数,在本文第三章中将运用深度学习算法建立

预测模型对规划时间段内的交通流信息进行预测。

## (2) 交通流量-速度模型

通过第三章建立的交通流预测模型，对我们所需要的路段进行了交通流量的预测后，我们得到了每条路段 $q_{ij}$ 的具体值，为了刻画速度与道路交通流量之间的关系，本文引用了速度-实用流量模型来计算配送车辆在该道路行驶时的速度。模型计算公式如下所示：

$$\begin{cases} V_{ij}(t) = \frac{V_{ij-0}}{1 + \left[ \frac{q_{ij}(t)}{Q_{ij}} \right]^\varepsilon} \\ \varepsilon = \mu + \sigma(q_{ij}(t))^3 \end{cases} \quad (2)$$

式中， $V_{ij-0}$ 表示从*i*节点到*j*节点的道路在零流状态下的速度，一般取该道路等级下的最大限速度。 $q_{ij}(t)$ 表示道路在*t*时刻时路段的交通流量的值，该值在第三章中将通过交通流量预测模型得到。 $Q_{ij}$ 为某道路等级条件下该路段单位时间内所通过最大车辆数。 $\mu$ 和 $\sigma$ 为不同道路等级下的自适应系数，取决于实际路段的道路等级。参考相关文献研究数据可知，在道路等级为I时， $\mu$ 和 $\sigma$ 分别取1.726和3.15；当该路段道路等级为II时， $\mu$ 和 $\sigma$ 分别取2.076和2.870；当该路段的道路等级为III时， $\mu$ 和 $\sigma$ 分别取2.395和2.565。

根据以上模型以及所有路段的交通流量的预测值，我们便可对物流配送车辆在某时间段行驶速度进行预测，进而可以预测其行驶过程中的能耗量。

### 2.1.2 电动车能耗模型

在2.1.1节中介绍了如何建立动态路网模型，以及如何通过实际路段的交通量计算物流配送的车辆行驶速度。在本节中将进一步根据已经得到的行驶速度建立能耗数学模型计算配送车辆在行驶过程中的能耗情况。

#### (1) 行驶能耗计算：

由于实际配送过程中，车辆的行驶状态与道路交通状态和驾驶员驾驶习惯相关，难以预测和量化，在此作出假设：配送车辆在每条路段行驶的状态为匀速直线运动。而电动车辆在一般道路上行驶时，阻力往往来源四个方面，即：加速度阻力、空气阻力、摩擦阻力和坡道阻力。其中由于假设配送车辆在路段中的运动为匀速直线运动因此加速阻力忽略不计。

其余阻力的计算式分别为以下所示：

空气阻力：

$$0.5C_d\rho Av_{ij}^2 \quad (3)$$

其中， $C_d$ 表示空气阻力系数通常取0.3左右； $\rho$ 为空气密度，通常取 $1.225\text{kg/m}^3$ ； $A$ 表示车辆的迎风面积； $v_{ij}$ 表示在2.1.1节中计算得到的车辆在路段 $s_{ij}$ 上的行驶速度。

坡道阻力：

$$M_i g \sin\theta \quad (4)$$

其中， $\theta$ 表示路段与水平方向的夹角。 $M_{ij}$ 表示车辆从*i*节点出发行驶至*j*节点的路段上的车辆质量。特别注意，由于物流配送车辆在配送过程中每经过客户点会卸下部分货物，

因此，此处的  $M_{ij}$  并非常量，其计算公式为  $M_{ij} = M_o - \sum m_{o-i}$ 。其中， $M_o$  表示从配送中心出发时的质量， $m_{o-i}$  表示从配送中心出发至  $i$  节点时所有的客户点卸载的质量。

摩擦阻力：

$$C_r M_i g \cos \theta \quad (5)$$

其中  $C_r$  表示车辆行驶路段上的摩擦阻力系数。

综上，可以计算出车辆在  $s_{ij}$  路段上的所有阻力之和，并进一步计算出配送车辆克服这些阻力所需要的功率：

$$P_{ij} = (0.5 C_d \rho A v^2 + M_i g \sin \theta + C_r M_i g \cos \theta) \frac{v_{ij}}{1000} \quad (6)$$

而计算动力电池输出功率  $ER$  需要考虑电动汽车的能量转换效率  $\eta$  因此动力电池输出功率为： $ER = P_{ij}/\eta$ 。由于车辆行驶速度  $v_{ij}$  已知，且路段长度  $d_{ij}$  已知，进而可以计算配送车辆在路段上克服阻力所做的工：

$$W_f(i,j) = ER \cdot t = ER \cdot \frac{d_{ij}}{v_{ij}} \quad (7)$$

(2) 考虑空调等附件的能耗计算：

由于电动车辆在行驶过程中能耗来源不仅来源于行驶阻力，同时空调等附件会消耗电动车辆的电能，因此考虑空调等附件的能耗后修正车辆做功：

$$W_f(i,j) = f \cdot ER \cdot \frac{d_{ij}}{v_{ij}} \quad (8)$$

其中  $f$  表示考虑附件耗电量的修正系数。

(3) 牵引力能耗和制动回馈计算：

虽然为了方便研究，我们假设忽略了高速公路路段中行驶的加速和制动能耗，但是在路口处的加速牵引力能耗是可以量化计算的，由于目前大多数车型都具有制动力回馈技术，在车辆进行制动时部分动能将回馈电池电量。设在  $i$  节点通往  $j$  节点的高速公路路段上存在红绿灯和收费站数量为  $n_{ij}$ ，因此根据动能定理可得：

牵引力能耗：

$$W_r(i,j) = \frac{1}{2\eta_1} M_i v_{ij}^2 n_{ij} \quad (9)$$

制动回馈：

$$W_b(i,j) = \frac{\eta_2}{2} M_i v_{ij}^2 n_{ij} \quad (10)$$

其中  $\eta_1$  表示电能转换为动能的效率系数， $\eta_2$  表示动能转换为电能的效率系数。则考虑空调等附件能耗、牵引力能耗和制动回馈后修正的在高速公路路段所做的总功为：

$$W_{ij} = W_f(i,j) + W_r(i,j) - W_b(i,j) \quad (11)$$

## 2.2 考虑充换电策略的电动车路径规划模型构建

在 2.1 节中，我们建立了动态交通路网模型，同时根据交通路网信息建立了电动车辆能耗模型，现在我们可以预测车辆在配送货物时的能量消耗，进而选择合适的时间补充合适的电量。由于配送货车在补充电量时，若选择充电，则充电时间较长，时间成本较高，同时充电会对动力电池产生损耗；若选择换电，虽然补充电量的时间短，但动力电池租赁成本较高，因此需要建立数学模型对电动物流车的充换电策略进行研究。因此，在本节中我们将考虑依据充换电策略建立数学模型。

### 2.2.1 充换电策略模型

在建立充换电决策模型时需要考虑包括如下几个方面的成本，其中经济成本是最直观的成本，而时间成本则代表潜在的客户对未按时送达的货物给予的时间窗惩罚成本。在下一节中将给出客户时间窗惩罚成本的数学模型。

$$\text{充电策略} \left\{ \begin{array}{l} \text{成本} \left\{ \begin{array}{l} \text{换电成本} \\ \text{充电成本} \left\{ \begin{array}{l} \text{电价成本} \\ \text{电池衰老成本} \end{array} \right. \end{array} \right. \\ \text{时间（客户惩罚成本）} \left\{ \begin{array}{l} \text{换电时间} \\ \text{充电时间} \end{array} \right. \end{array} \right.$$

(1) 充电成本

①充电分时电价成本

由于大多数补电站其充电电价常常使用分时电价，在充电高峰期电价通常较高，因此考虑分时电价影响建立计算充电价格的数学模型如下：

首先假设补电站充电收费分时电价如下：

$$ch = \begin{cases} C_1 & t_i \in (t_1, t_2) & i \in F & \text{峰时} \\ C_2 & t_i \in (t_2, t_3) & i \in F & \text{平时} \\ C_3 & t_i \in (t_3, t_4) & i \in F & \text{谷时} \end{cases} \quad (12)$$

其中， $C_1$ 、 $C_2$ 、 $C_3$  分别表示充电峰时、平时和谷时的电价； $F$  表示电站节点集合。

在选择充电量时，为节约成本、缩短充电时间，本研究采取部分充电的策略。即，补充电量到达可以完成配送任务并返回车站时停止充电，无需充电到动力电池满电。根据 2.1 章节中建立的能耗模型可以计算得到到达电站时的电量和离开电站时的电量。

到达电站时的电量：

$$Q_1 = Q_e - \sum_{i \in V} \sum_{j \in V} x_{ijk}^1 \cdot W_{ij} \quad (13)$$

其中， $Q_e$  代表从车站出发时的原始电量，这里我们假设每辆车从车站出发时都是以满电状态出发； $V$  表示路网中的所有节点集合； $x_{ijk}^1$  为决策变量表示车辆到达电站前  $k$  是否经过  $i$  节点到  $j$  节点的路程，若是则为 1，否则为 0； $W_{ij}$  为在 2.1 节中建立数学模型计算的从节点  $i$  到节点  $j$  之间的能耗量。

离开电站时的电量：

$$Q_2 = \begin{cases} \left( \sum_{i \in V} \sum_{j \in V} x_{ijk}^2 \cdot W_{ij} \right) \cdot \eta & Q_2 < 0.8Q_e \\ 0.8Q_e & Q_2 \geq 0.8Q_e \end{cases} \quad (14)$$

其中,  $x_{ijk}^2$  表示车辆离开电站后还需要访问的节点,  $\eta$  为计算容错率, 防止因计算误差或其他无法量化的影响因素导致的车辆在行驶到车站前中电量耗尽。若访问剩余节点所需电量大于电池总电量时, 则考虑到一次充电无法满足要求, 为尽快完成充电只需要将电池充至总电量 80%即可。

根据以上计算, 即可计算出采取充电策略时补充电量的成本:

$$C_{ch1} = (Q_1 - Q_2) \cdot ch \quad (15)$$

## ②动力电池损耗成本

当选择充电策略补充电量时, 考虑成本时还需考虑充电对于动力电池损耗的影响。已有不少学者展开了充电对动力电池使用寿命的研究, 在此我们直接引入动力电池损耗模型计算单位放电成本:

$$K^{DOD} = \frac{C_B}{L(1-y)} \quad (16)$$

其中  $C_B$  为单个购置电池的成本,  $L$  为电池全生命周期下的总放电量,  $y$  为电池损耗系数。因此电池损耗成本可以通过总消耗电量乘以单位放点成本来折算:

$$C_{ch2} = \sum_{k \in K} \sum_{i \in V} \sum_{j \in V} \alpha \cdot K^{DOD} \cdot W_{ij} \cdot x_{ijk} \quad (17)$$

因此充电总成本可以计算为:

$$C_{ch} = C_{ch1} + C_{ch2} \quad (18)$$

## (2) 充电时长

考虑到配送车辆到达充电站有可能需要进行充电排队的情况, 为了后续计算时间惩罚成本, 在此计算配送车辆充电时长时考虑充电排队时长。我们引入排队模型  $M/M/N/\infty/\infty$  用来计算充电排队时长。

### ①排队时长:

设充电站有充电桩  $N$  个, , 且充电站的服务强度为  $\rho = \lambda/\mu$ , 车辆到达率为  $\lambda$ , 每个充电桩的平均服务时间为  $\frac{1}{\mu}$ , 则根据排队论模型可计算没有充电用户的概率为:

$$P = \frac{1}{\sum_{n=0}^{N-1} \frac{\rho^n}{n!} + \frac{\rho^N}{N! (1 - \rho/N)}} \quad (19)$$

平均排队长度为:

$$L_q = \frac{P \rho^{N+1}}{N! N} \left[ \frac{1}{(1 - \rho/N)^2} \right] \quad (20)$$

则平均排队时间:

$$T_{wait} = \frac{L_q}{\lambda} \quad (21)$$

## ②充电时长:

由于大多数充电桩的充电特性在动力电池总电量 80%之前近似线性,而在充到总电量的 80%之后为保护电池充电速度逐渐下降,充电效率降低,将大大增长充电时间,因此我们假设采取充电策略时,若剩余路程的所需电量大于等于电池总电量的 80%,则司机在以恒流充电功率 $r$ 充到总电量的 80%后便停止充电,充电时长计算公式如下

$$T_{char} = \frac{Q_2 - Q_1}{r} \quad (22)$$

## (3) 换电成本

由于换电时长与换电成本通常变化不大,因此在本研究中我们认为换电成本与换电时长分别为常量。换电成本为 $C_{ef}$ ;换电时长为 $T_{ef}$

## 2.2.2 目标函数建模

在建立了以上模型后就可以对车辆路径规划的目标函数进行数学建模。在计算总成本时,配送总成本来源有以下几个方面:

$$\text{总成本} \begin{cases} \text{客户惩罚时间成本 } C_t \\ \text{车辆使用成本 } C_k \\ \text{充/换电成本 } C_e \\ \text{运输成本 } C_r \end{cases}$$

其中,客户惩罚时间成本表示未按客户指定时间内送达的货物,配送公司需要被惩罚一定数量的金额;车辆使用成本表示包括车辆本身的成本以及驾驶员工资等固定成本;充换电成本表示在 2.2.1 节中建立的充换电策略模型中,当车辆进行充电时造成的经济成本;运输成本表示随着运输路程的增加部分货物会被损坏,其成本大小仅与路程长短相关。

### (1) 客户惩罚时间成本

学者们提出了不同的时间窗惩罚成本 $C_t$ 的数学模型,包括软时间窗(惩罚成本与迟到/早到时间相关)、硬时间窗(惩罚成本与到达时间无关)、混合时间窗、多时间窗等模型。在本研究中考虑到不同客户对于时间惩罚的习惯不同,为了简化模型,因此假设所有客户的均采用如下所示的时间窗惩罚函数。

如下图所示为软时间窗惩罚成本与车辆到达时刻相关的函数图像。

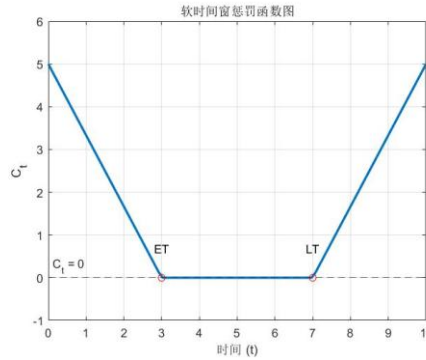


图 2.2 软时间窗惩罚函数图



其中  $ET$  表示车辆要求到达的起始时刻， $LT$  表示车辆要求到达的最终时刻。如图所示，在  $ET$  时刻与  $LT$  时刻之间的部分惩罚成本为 0，而在其他时刻，则会因为到达时间距离要求到达时间长短而增加惩罚成本。时间惩罚成本的数学表达式如下所示：

$$C_t = \sum_{i \in I} [epu \cdot \max(ET_i - t_{ik}, 0) + lpu \cdot \max(t_{ik} - LT_i, 0)] \quad (23)$$

其中， $i$  表示客户节点； $I$  为客户节点集合； $epu$ 、 $lpu$  表示所有客户惩罚时间窗的斜率； $ET_i$  与  $LT_i$  表示客户节点  $i$  对配送公司配送到达时间的起始时刻和结束时刻的要求； $t_{ik}$  表示对于  $k$  车辆，在到达  $i$  节点时的时刻。由于我们在 2.2.1 章节中介绍了采取充换电时充换电时长的计算，同时在 2.1 章节中建立了交通路网模型，配送车辆在路程中的行驶时间也可以计算得到。假设忽略配送时装卸货物的时长，根据以上信息在路径规划时便可以预测配送车辆按规划路径行驶到达客户  $i$  节点的時刻。

#### (2) 车辆使用成本

车辆使用成本是与使用车辆相关的常量成本，包括车辆成本、驾驶员工资等，其仅与配送车辆的使用数量相关。其数学表达式如下：

$$C_k = \sum_{k \in K} C \cdot x_k \quad (24)$$

其中  $C$  表示单个车辆的使用成本，这里为简化模型假设所有车辆的使用成本相同； $x_k$  为决策变量，取值为 0/1，表示是否启用车辆  $k$ ； $K$  为车场集合。

#### (3) 充/换电成本

根据 2.2.1 建立的充换电成本的数学模型中，公式 (15) 计算了充电电价成本，公式 (17) 计算了动力电池损耗成本，并且认为换电时的成本为固定成本，利用决策变量可以将充换电成本总结为以下公式：

$$C_e = \sum_{k \in K} \sum_{i \in H} (x_{kih} \cdot C_{ch} + x_{kif} \cdot C_{cf}) \quad (25)$$

其中  $H$  代表充电站集合， $x_{kih}$  和  $x_{kif}$  为决策变量，当车辆  $k$  访问电站  $i$  采用充电策略时， $x_{kih}$  为 1 且  $x_{kif}$  为 0；反之，当车辆  $k$  访问电站  $i$  采用换电策略时

#### (4) 运输成本

运输成本为在运送途中产生的成本，仅与行驶总路程相关。其数学表达式为：

$$C_r = \sum_{k \in K} \lambda \cdot r_k \quad (26)$$

其中， $\lambda$  表示单位行驶路程造成的运输成本， $r_k$  表示对于车辆  $k$  完成配送时行驶的总路程。

#### (5) 总成本目标函数

综上所述成本函数用数学表示为：

$$C_{\text{成本}} = \min(C_t + C_k + C_e + C_r) \quad (27)$$

### 2.2.3 约束条件与问题假设

#### (1) 约束条件

①客户点访问约束：每个客户点只访问一次。

- ②节点流量守恒：每辆车访问一个节点后要从该节点驶出。
- ③配送车辆数量不多于配送中心车辆总数。
- ④每辆配送车的载货量要小于其允许的最大载货量。

## (2) 问题假设

根据上述建立的数学模型，总结在本模型中进行的假设如下：

- ①车速在较短时间内保持恒定。
- ②假设物流配送车辆只向客户点送货不取货。
- ③假设只有一个配送中心，所有电动车从配送中心出发去客户点送货，并返回配送中心。
- ④使用同型号的配送电动物流车，且从配送中心出发时动力电池为满电状态。
- ⑤忽略装卸货物的时间，且忽略在装卸货物过程中电动车辆在静止状态下的电量消耗。
- ⑥每个客户点只被访问一次。
- ⑦物流车在节点与节点之间的路途中除交通路口与收费站外的路段均保持匀速行驶。
- ⑧假设每条路段的交通流量情况大致相同。

## 2.3 本章小结

本章我们首先建立了交通路网模型和电动车辆能耗模型，并在此基础上建立了考虑交通流量影响的电动车辆路径规划的数学模型，以及考虑充换电策略的电动车辆路径规划数学模型，为后面实验建立遗传算法求解提供理论基础。

## 第三章 考虑交通流预测的路径规划

当物流公司在进行配送车辆的路径规划时,道路的交通拥堵情况往往会直接影响配送的效率和成本。在本论文第二章中,我们介绍了本研究中建立的电动物流车辆路径规划的数学模型,在模型中我们引入了道路流量-速度实用模型。通过预测的道路交通流量,计算预测的车辆经过道路时的平均通行时间与平均通行速度,进而计算各种成本。由此可知,对道路交通流预测结果的准确与否对于模型成本计算的准确性和路线规划方案的实用性至关重要。因此,本研究提出了一种基于道路历史交通流数据建立的长短时记忆神经网络(LSTM, Long Short-Term Memory)模型,并利用完全集成经验模态分解(CEEMD)技术对预测模型进行改进提高预测的准确率,以此预测道路交通量。

### 3.1 相关理论基础

由于本章中所介绍的交通流预测模型引入了 EMD 技术和深度学习技术,由于本章中所提及的技术并非传统车辆工程领域,为更清晰的展示本章中所搭建的模型,本节中将进行相关理论知识的引入。

#### 3.1.1 长短时记忆神经网络

##### (1) 深度学习基本概念

深度学习作为机器学习的一个分支,主要通过搭建多层神经网络模型,并对该模型进行训练以完成数据挖掘、模式识别等任务。如下图所示即一个简单的人工神经网络结构模型示意图,其中左边一层称为输入层,中间一层称为隐藏层,最右边一层称为输出层。

神经网络的基本单元称为神经元,在神经元中分别对输入数据先后进行一次线性和非线性运算。每个神经元与神经元之间的权重不同。神经网络模型通过计算损失函数,评估输出值与实际值之间的相似性,并依据损失函数利用梯度下降算法进行反向传播调整各个节点的参数,使模型输出值的损失最小,此时便得到最准确的模型。




图 3.1 人工神经网络结构图

随着计算机算力的不断提高以及人工智能技术的不断发展,深度学习技术已被广泛应用于交通流预测领域。当前利用深度学习模型进行交通流预测任务的研究大致分为两类:一类是基于空间特征采用卷积神经网络(CNN)进行预测的模型,一类是基于时间特征采用循环神经网络(RNN)进行预测的模型。考虑到单一道路交通流具有明显的时间序列特征,

本研究将采取长短时记忆神经网络（LSTM）模型对道路交通流进行预测分析。

### （2）传统循环神经网络

LSTM 模型是循环神经网络（RNN）的一种变体。如下图所示，为循环神经网络的一般结构形式。循环神经网络与普通人工神经网络模型的不同之处在于，在其隐藏层中，不仅不同层的神经元之间需要进行数据的计算，同一层的神经元之间也需要进行加权计算。其作用可以使神经网络在处理时间序列数据（如交通流量数据）时，学习到不同时间步数据之间的信息。RNN 经常被用于处理时间序列问题，交通流就是典型的时间序列问题。时间步的概念是指，在时间序列数据中，每个时间步对应一个序列的元素。例如，在一个每隔五分钟进行一次检测的道路交通流数据中，一个时间步的数据就是以此检测时该路段交通流量的大小，而其下一个时间步数据即五分钟后下一次检测得到的交通流的大小。




图 3.2 循环神经网络结构图

传统的 RNN 模型被广泛应用于时间序列数据的预测。但是，传统的循环神经模型无法辨别不同时间步的信息哪些对于输出是重要的。同时，RNN 存在新信息会强制覆盖旧信息，导致模型无法形成长期记忆的问题。这使得传统的 RNN 模型对于被影响周期较大的交通流数据难以进行准确预测，无法学习到长时间序列上的影响。

基于以上问题，研究者们希望开发出一个新的架构 LSTM 模型，使循环神经网络能够对信息进行选择性保留和遗忘，从而增强模型长期记忆的能力。同时，LSTM 模型解决了传统神经网络中梯度爆炸和梯度消失的问题。

### （3）LSTM 模型原理

如下图所示为 LSTM 架构的一般示意图，其结构与传统的 RNN 结构十分相似，都包含输入层、输出层以及隐藏层结构，且输入均为不同时间步上的数据。其不同之处在于，在 LSTM 模型的隐藏层中，每个神经元结构被替换为一种可以对信息进行选择性记忆和遗忘的结构单元，称为记忆细胞。而不同记忆细胞在数据传递时，也与传统循环神经网络不同， $t-1$  时间步的记忆细胞向下一个时间步的记忆细胞分别传递  $H_{t-1}$  和  $C_{t-1}$  两个值， $t$  时间步的记忆细胞通过对前一个时间步记忆细胞传递的两个值进行计算，得到输出以及向下个记忆细胞传递的两个值  $H_t$  和  $C_t$ ，以此类推。其中  $H_t$  主要负责存储短期记忆信息，而  $C_t$  称为细胞状态，主要负责存储长期记忆信息，两个变量会跟随时间步不停迭代，从而不断更新记忆细胞的短期记忆和长期记忆。

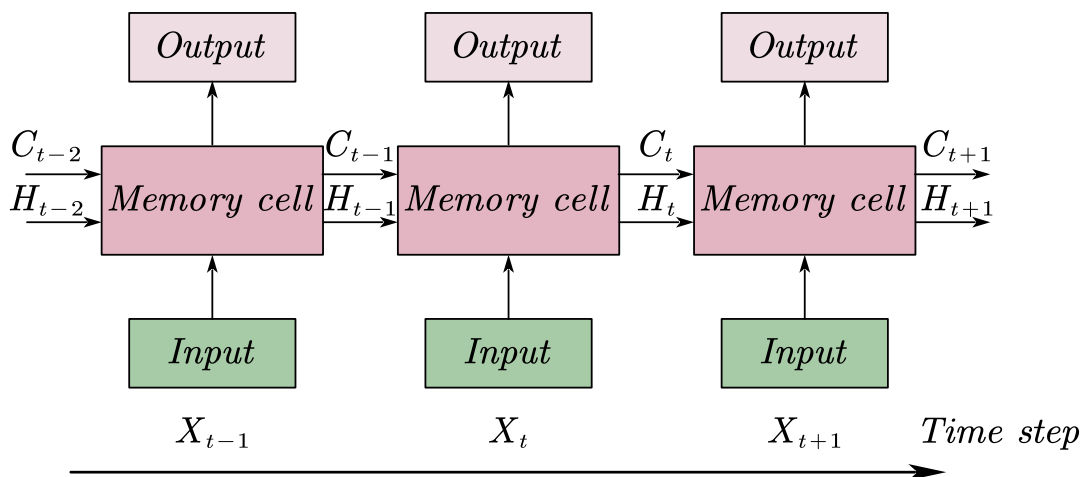


图 3.3 LSTM 结构图

如下图所示为记忆细胞的内部结构示意图。记忆细胞通过三个门控单元实现对时序数据信息的选择记忆和遗忘的功能，三个门控单元分别为：遗忘门、输入门和输出门。

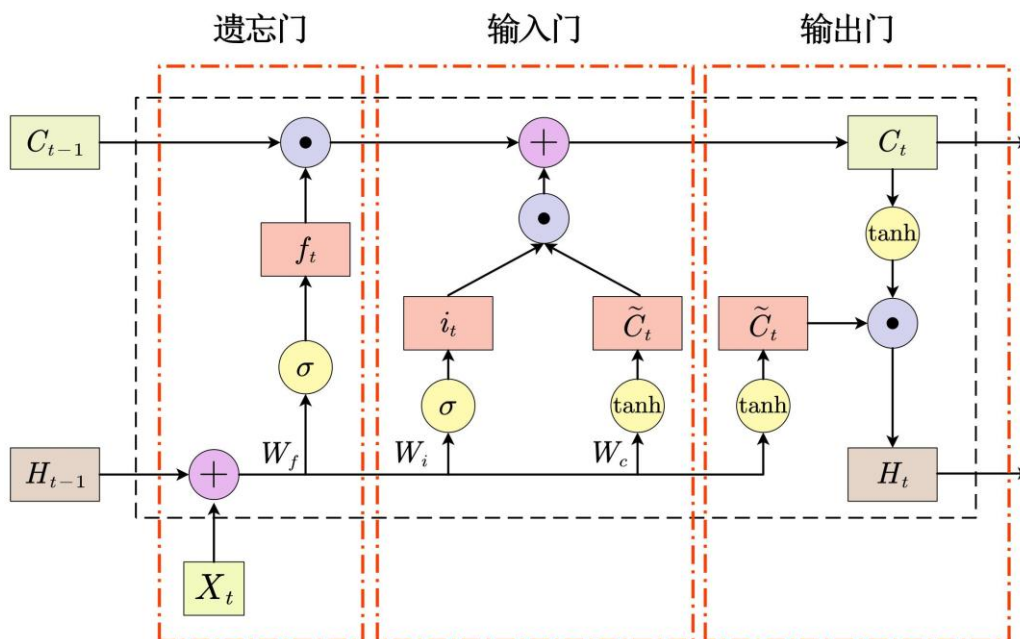


图 3.4 记忆细胞结构图

如上图左侧方框里结构即遗忘门门控单元示意图，遗忘门用于决定保持多少长期记忆。其数学本质在于对保存长期记忆的细胞状态参数乘以一个范围在 (0,1) 之间的系数  $f_t$ ，以决定筛选掉多少历史信息。而决定这个系数的大小则是通过参考当前时间步的信息  $X_t$  与上个时间步的短时记忆信息  $H_t$  计算得到。其数学计算公式如下所示：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (28)$$

其中， $\sigma$  是 sigmoid 函数， $W_f$  是动态影响最终权重大小的参数，他会根据损失函数的表现进行调整从而不断调节计算出的  $f_t$  的大小。Sigmoid 函数表达式： $S(x) = \frac{1}{1 + e^{-x}}$ 。

其值域范围在 (0,1) 之间。因此，通过此计算公式得到的  $f_t$  的值也再 (0,1) 之间。

如上图中间方框里结构即输入门控单元，输入门用于决定从当前时间步的输入数据中要吸纳多少新信息加入至长期记忆细胞  $C_{t-1}$  中。其数学本质在于对当前时间步传入的所有信息  $\tilde{C}$  乘以一个大小在 [0,1] 之间的参数  $i_t$ ，以筛选掉部分新信息，将剩余的新信息融入长期记忆细胞状态  $C_{t-1}$  中。在这个过程中首先要计算参数  $i_t$  的大小，其计算过程与遗忘门中参数  $f_t$  计算过程类似。参数  $\tilde{C}_t$  则表示对当前时间步下的输入一共有多少记忆信息。其数学公式如下所示：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (29)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (30)$$

计算得到参数  $i_t$  加入记忆信息的比例和  $\tilde{C}_t$  新记忆信息的总量两个参数后，进行点乘运算即可得到加入的新的记忆信息，将其加入上一个时间步输出的细胞状态后对细胞状态进行更新得到当前时间步下的细胞状态  $C_t$ ，完成细胞状态的迭代，其数学运算过程如下所示：

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (31)$$

如上图所示，右侧方框内结构即输出门控单元。输出门的作用是从当前已经迭代过的长期记忆信息  $C_t$  中筛选出最适合当前时间步的短期信息  $h_t$ 。其数学本质是令已经计算好的长期信息  $C_t$  乘以一个 [0,1] 之间的比例  $o_t$ ，以此筛选出对当前时间步最有效的信息用于当前的时间步的预测。首先根据前一个时间步的输出  $h_{t-1}$  和当前时间步的输入，通过权重  $W_o$  计算出比例参数  $o_t$ ，接着对迭代后的长期记忆信息  $C_t$  进行标准化处理，抑制长期记忆信息的数字范围，避免历史信息在传递过程中越来越大，最后将两个参数进行点乘筛选出当前时间步下的输出。其数学运算过程如下所示：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (32)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (33)$$

以上我阐述了 LSTM 架构的原理和数据经过记忆细胞中所进行的数学计算流程。在后面面对预测模型的搭建中我将引入 LSTM 架构完成。

### 3.1.3 经验模态分解 (EMD)

在 3.1.2 中介绍了 LSTM 模型的原理，在搭建的预测模型中不仅使用了 LSTM 模型，同时引入了经验模态分解技术 (EMD) 处理交通流信息，EMD 技术应用于处理非平稳信号的局部频谱分析。非平稳信号即震荡频率随时间变化的信号，交通流数据则体现了这一特点，本节将介绍经验模态分解技术中的相关概念。

(1) 本征模态函数 (IMF) 的定义：

函数  $f^{(x)}$  若满足：(1) 极值点与零点的数目相差不超过 1；(2) 上下包络线函数的均值为 0。则称  $f^{(x)}$  为 IMF。其中上包络线函数为极大值点的包络函数，下包络线函数为极小值点的包络函数。可以利用插值函数的方法实现。




图 3.5 EMD 分解图示

## (2) EMD 技术:

将给定函数分解为若干本征模态函数及单调的残差。如上图所示，为利用 MATLAB 绘制对函数  $u(x)$  进行 EMD 分解后得到的下面两个 IMF 函数的简单示例。EMD 技术的数学表达形式如下所示:

$$u(t) = \text{Im } f_1(t) + \text{Im } f_2(t) + \dots + \text{Im } f_N(t) + r_N(t) \quad (34)$$

## (3) shifting 算法:

shifting 算法是寻找 IMF 的方法，其算法流程为:

- ①对给定函数  $u(t)$  找出所有极大值点和极小值点
- ②使用样条曲线拟合出极大值点包络线和极小值点包络线
- ③对两条包络线进行平均得到平均线
- ④原函数减去平均线得到新的函数  $h_1(t)$

⑤用新函数  $h_1(t)$  代替  $u(t)$  重复 1-4 操作，直到得到函数  $h_k(t)$  ( $k=2,3,\dots$ ) 满足 IMF 条件为止。

⑥令  $u(t) - h_k(t)$  得到新函数  $u_1(t)$  令其代替原函数重复操作 1-5 直到最终函数本身近似为 IMF 函数或本身近似为单调函数为止找到所有的 IMF 函数

## (4) 完全集成经验模态分解 (CEEMD)

由于 EMD 具有一定缺陷：一个单独的 IMF 信号中可能含有不同频率的信号，而且相同的频率的信号可能出现在不同的 IMF 中。由于在进行 IMF 分解时最理想的情况是将不同



频率的信号分为不同 IMF 这样便于预测网络模型提取不同频率周期的特征。所以本文采用完全集成经验模态分解（CEEMD），其优势不但解决了上述问题，对比 EEMD 降低了噪声对于输出结果的影响。

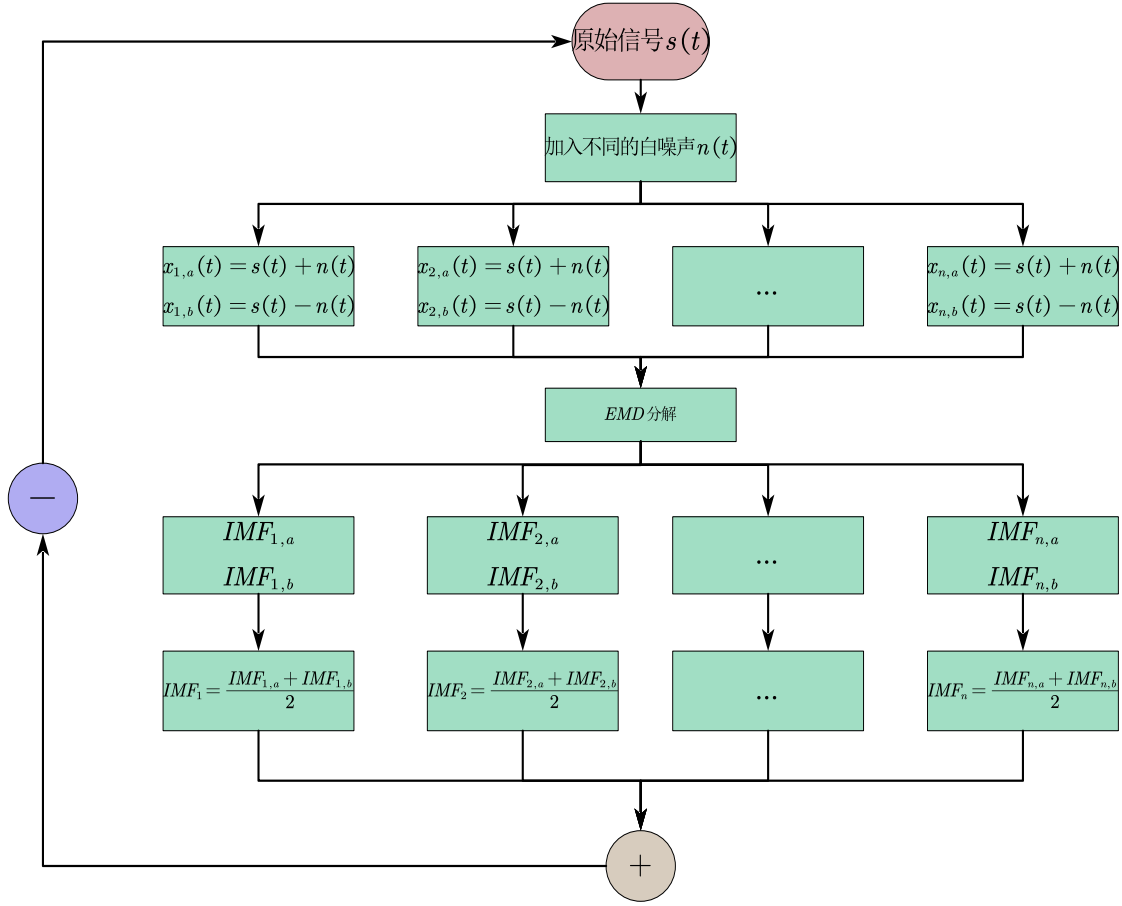


图 3.6 CEEMD 工作流程图

如上图所示为 CEEMD 模型的工作流程图，先对原始信号分为  $n$  组分别加减不同的高斯噪声信号，每组内加减的噪声相同，每组之间噪声不同，然后分别分解每组两个信号的 IMF，分别对 IMF 的值进行平均，以消除噪声对结果的影响，最后将每组的结果进行相加即可得到分解的最终 IMF 函数，将原始信号减去最终得到的 IMF 信号重复该过程直到得到所有的 IMF 信号。

### 3.2 道路交通预测模型介绍

下图所示为本研究提出的交通流预测模型的工作原理图，其工作流程为，首先利用 CEEMD 技术对某路段交通流数据进行 IMF 分解，将其分解为不同频率特性的 IMF 函数，然后利用 LSTM 神经网络模型分别对各个 IMF 函数进行预测，预测路径规划所需时间内的各个 IMF 函数的变化，然后将所有 IMF 函数进行求和，即得到最终预测的结果。

该模型更加关注学习交通流随频率变化的特征，例如天气、上下班高峰、节假日等对交通流不同频率的影响因素该模型的学习效果较好，可以预测出当天该时间段内车辆通行的大致流量以及流量的上升下降的趋势。但是 LSTM 作为时序预测模型，只能捕捉到时间维度的特征，无法学习到空间上的特征，即无法对路段与路段之间的交通流影响进行学习和预测，



这也是本模型的局限性。

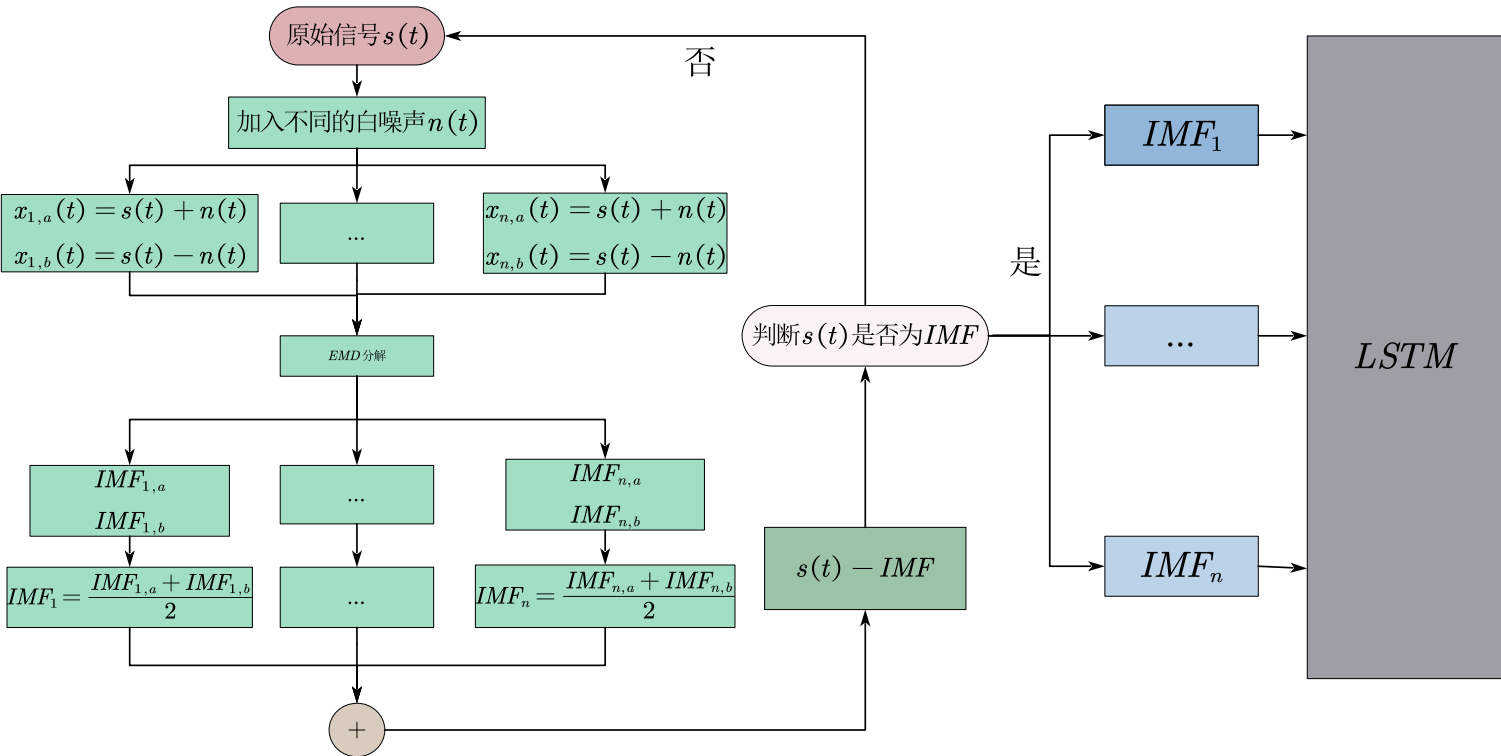


图 3.7 交通预测模型工作原理图

### 3.3 交通流量预测算法实验

为验证本研究所提出的模型算法的可行性，本节将根据上述搭建的模型算法进行城市交通流量预测的相关实验。

#### 3.3.1 实验数据

为验证前面提出的交通流量预测算法，本研究选择采用网络开源数据集进行实验验证，数据集网址:<http://www.openit.cn/openData2/792.jhtml>。该数据集由 2016 年 8 月 1 日至 2016 年 9 月 30 日期间，中国广州市 214 个匿名路段组成，间隔 5 分钟采集的路段平均行驶车速数据，主要包括城市高速公路和主干道，符合本研究内容，具体数据结构如下图所示。

	A	B	C	D
1	road id	day_id	time_id	speed
2	1	1	1	40.893
3	1	1	2	41.938
4	1	1	3	44.098
5	1	1	4	44.483
6	1	1	5	44.172
7	1	1	6	44.416
8	1	1	7	43.622
9	1	1	8	44.202
10	1	1	9	42.898
11	1	1	10	44.123
12	1	1	11	46.065
13	1	1	12	46.248
14	1	1	13	48.178
15	1	1	14	44.784

图 3.8 数据集节选

为实验验证本研究所使用的交通流量预测算法的有效性，实验选取了 road\_id 为 1 的路段 31 天内的 4464 个数据作为实验数据集，并将数据集划分为训练集和测试集，将其中按照时间排序的前 4352 个样本作为数据集，因为本研究任务需预测一天内的道路车速，因此将最后一天内的后 112 个样本作为测试集，对上述数据集进行实验验证预测算法的准确率和效果。分别对训练集和测试集数据进行可视化如下图所示：




图 3.9 数据集可视化

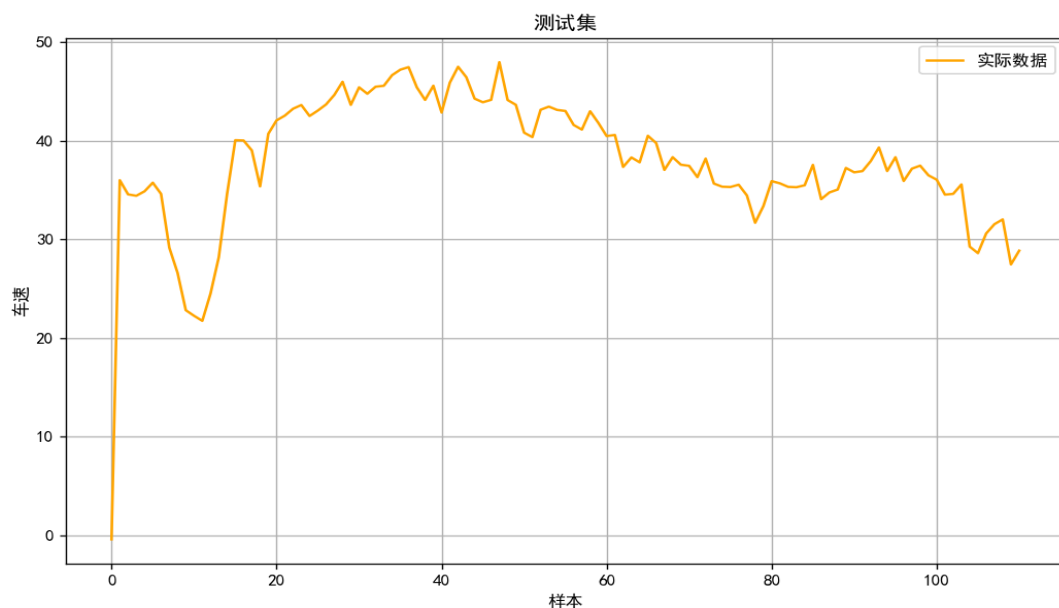


图 3.10 测试集数据可视化

由上图可以发现，在编号为 road\_id=1 的道路中，在节选的 31 天内的车速数据中呈现明显的周期性变化。

### 3.3.2 CEEMD 技术数据处理

根据上述模型描述，先对训练集中的数据利用 CEEMD 技术进行分解，将该时序数据分解成多个 IMF 函数，将训练集中的 4352 个样本输入 CEEMDAN 模型中进行经验模态分解，将其分解成 10 个不同频率下的 IMF 函数分别如下所示：

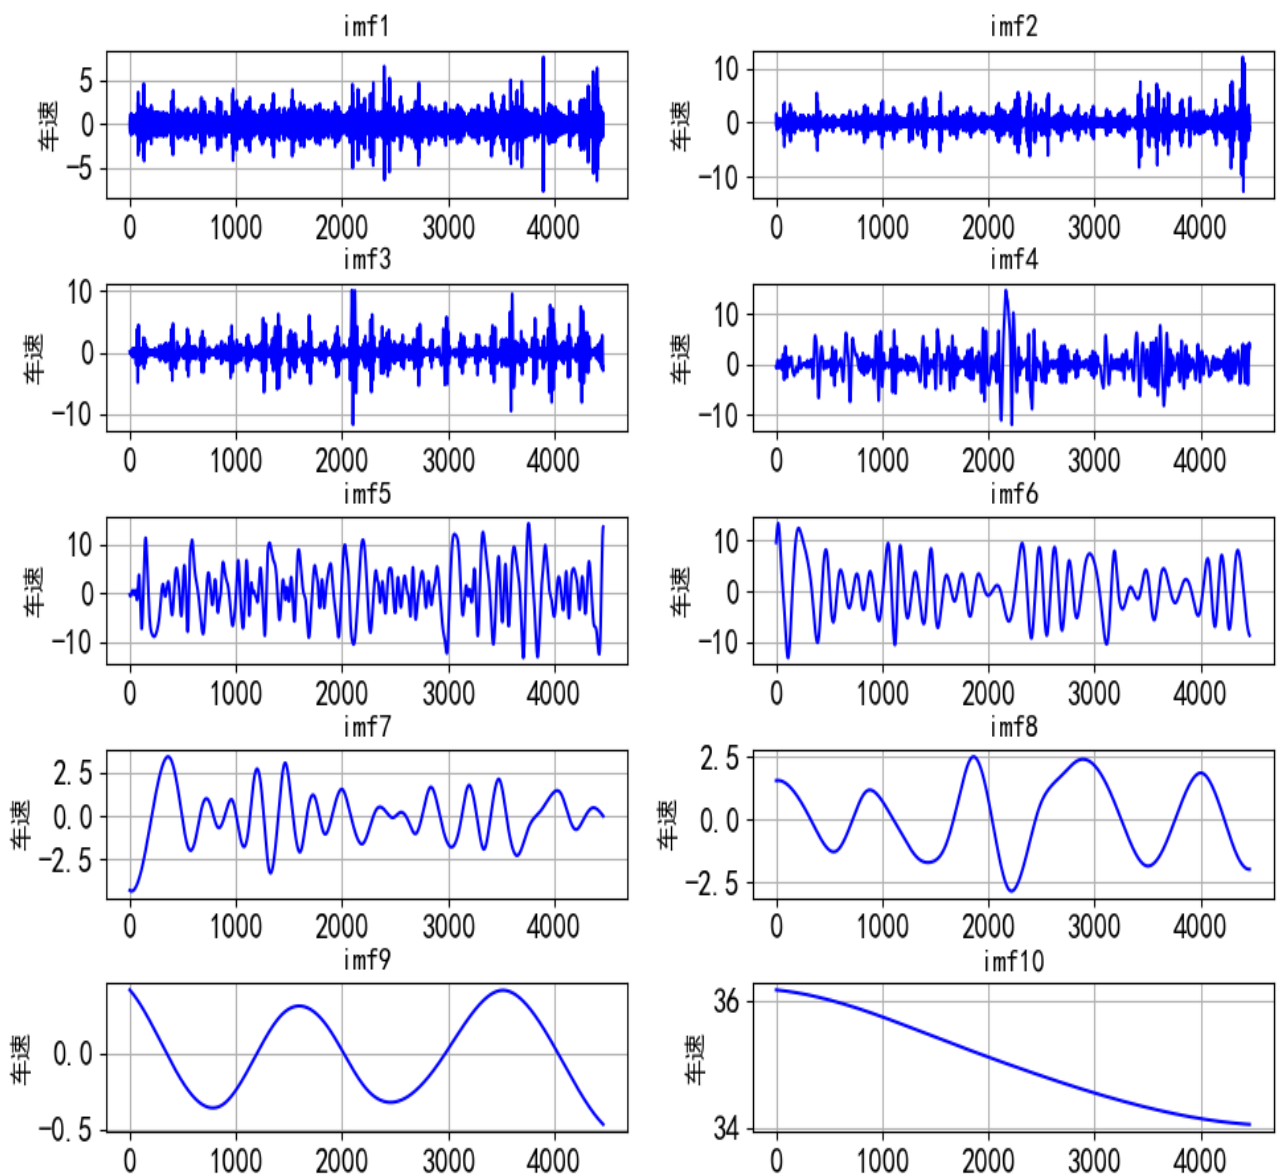


图 3.11 训练集 CEEMD 分解结果

通过应用 CEEMD 算法对短时流量进行分解，我们得到了 10 个成分，包括 IMF1 到 IMF10。如上图所示，IMF1 代表随机成分，包含了原始信号中较高频率和短时间尺度的信息，表现出较强的波动性和频率特征。IMF2 至 IMF8 则是细节成分，构成了原始信号的重要部分。对这些细节成分的边缘、纹理和小波动等特征进行分析，有助于深入理解信号中的快速变化特征，这些信息可用于后续的特征提取和细节预测。而 IMF9、IMF10 表示趋势成分，包含较低频率和较长时间尺度的成分，反映了原始信号的整体趋势或长期变化。

### 3.3.3 实验结果分析

将数据集分解成如上图所示的 10 个 IMF 本征模态函数后，分别将其输入利用 Pytorch 部署的 LSTM 模型并对 LSTM 模型进行训练，完成训练后分别每个频率下的 IMF 函数的未来 112 个数据进行预测输出。由于本实验仅验证算法可行性，因此在对 LSTM 深度学习模型进行超参数的设计时并没有进行细致的选择，其相关超参数选择如下表所示：

表 3-1 LSTM 模型超参数设定

基础学习率	权重衰减系数	堆叠层数	隐层维度
0.01	0.001	2	128

得到预测解结果与实际结果进行对照如下图所示,其中蓝色线条表示预测值而黄色线条表示实际值。

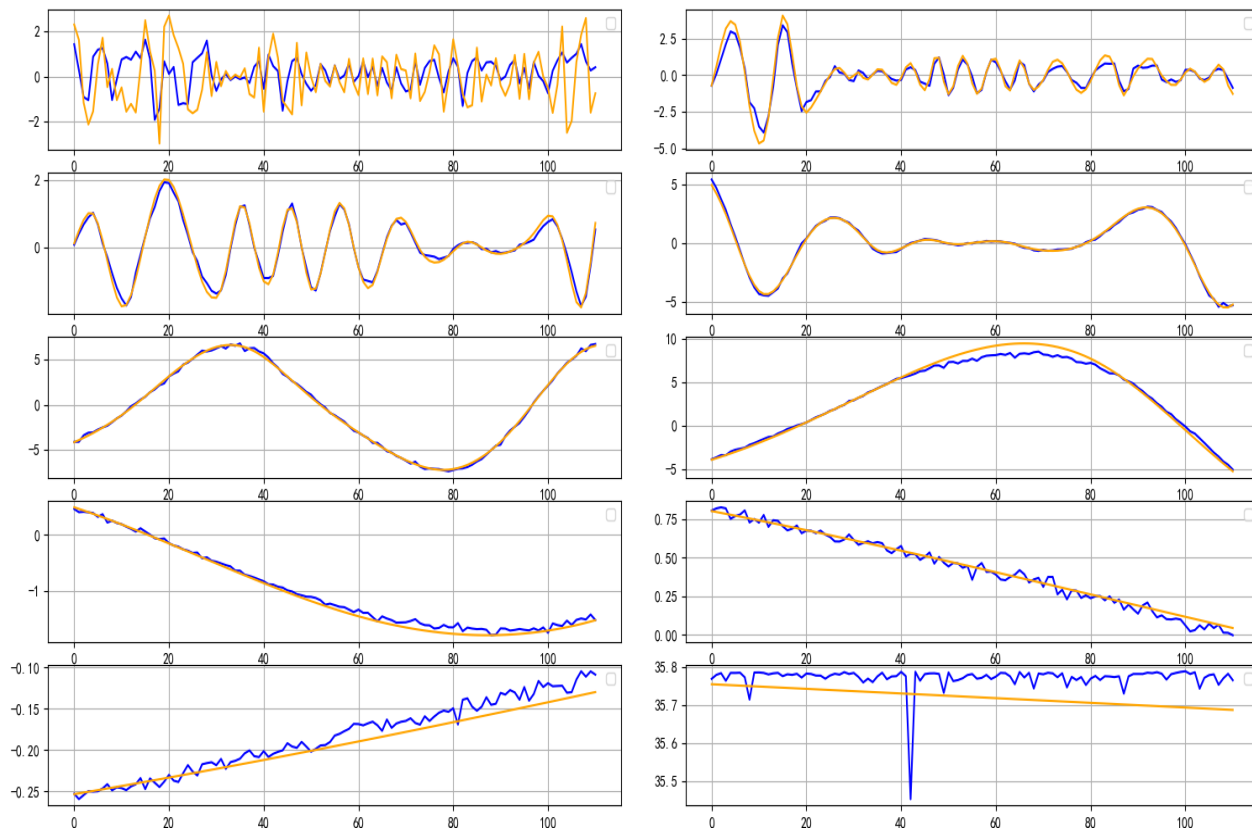


图 3.12 LSTM 模型预测 IMF 结果

由上图得到的预测模型结果我们可以分析得出, LSTM 模型对于低频信号的预测较为精准, 对于高频信号如 IMF1, 只能预测其大致的变化规律、震荡周期, 对于振荡幅度难以精准预测。将上图中显示的预测得到的 10 个不同频率下的 IMF 函数进行数值加和, 即可得到最终对测试集进行预测的预测值。将预测值与测试集实际值进行对比如下图所示:

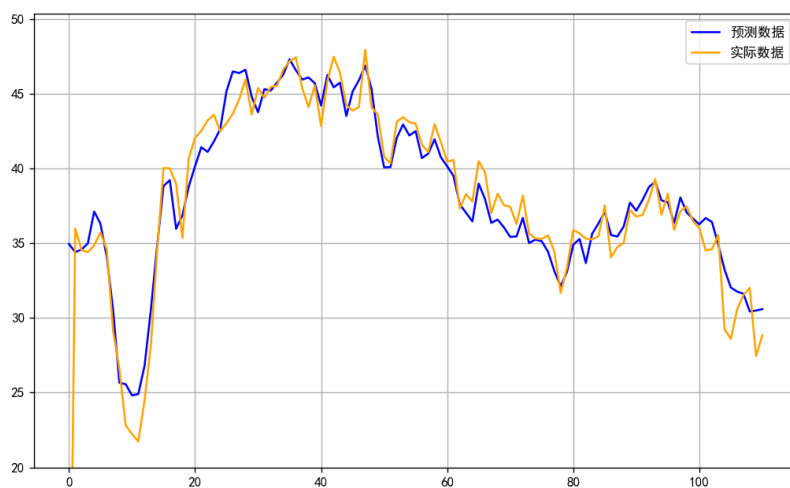


图 3.13 模型整体预测结果

由上图可以分析,本模型对短时交通流量预测可以较为准确的模拟整体交通流量变化的趋势,但在细节方面与真实值之间的差距较为明显。

### 3.4 本章小结

本章我们首先列举了建立交通流量预测模型所需要的基本理论知识,然后建立了CEEMD-LSTM深度学习模型来预测道路交通流量,最后实验结果显示模型具有较为准确的预测能力,可以较为准确的预测交通流量的变化趋势,得到的预测结果可以应用于后续的路径规划算法实验中。

## 第四章 算法设计与实验分析

在第二章中，我们提出了考虑交通流量的路径规划数学模型。在第三章中，我们建立了 CEEMD-LSTM 算法来实现交通流量的预测，并进行相关可行性试验，实验结果表明，本研究提出的交通流量预测算法是有效且可靠的。基于以上模型算法，本章将搭建基于遗传算法的路径规划求解算法，并进行相关实验验证证明算法的可行性，以及数学模型的有效性。

### 4.1 遗传算法设计

车辆路径规划问题，是指在满足客户需求的前提下，优化车辆的行驶路线方案，以达到最优成本、最优收益等目标。车辆路径规划问题属于组合优化类问题，在第二章中我们已经建立出了本研究所关注的数学模型，对路径规划过程中产生的成本进行了模型建立，在数据集中我们可以得到完成每项客户任务所获得的价格，从而可以得到最终的物流配送利润。将利润作为优化目标即可建立求解算法。

#### 4.1.1 路径规划类问题求解算法

目前，关于路径规划类问题的求解算法的研究已经相当成熟，根据算法类型大致可以分为三类。一是精确式算法，通过数学方法处理模型，得到问题的最优解，如分支定界法、割平面法、网络流算法，这类算法属于枚举类型，虽然可以计算得到最优路径配送方案，但是由于计算复杂度较高，在大规模客户数量的规划中计算量过大，无法满足实际应用要求。二是启发式算法，利用生物物理等特性，对解进行多次迭代，快速得到满意解。如遗传算法、模拟退火法、蚁群算法、鲸鱼算法等进化算法。该类算法能够在较短时间内得到满意解，但容易陷入局部最优，难以寻找到全局最优方案。三是元启发，元启发式算法是对启发式算法的改进，通过引入随机干扰算法，以防止算法陷入局部最优，常见的元启发式算法有禁忌搜索算法，大规模邻域算法等。

遗传算法是用于解决优化问题的一种搜索算法，借用了达尔文进化理论，其算法基本原理如下：首先生成初始解，解可以用物流车访问地点序号的先后排序来编码表示。依据前面建立的数学模型计算每个初始解对应的目标函数值，目标函数值越接近我们期望的解越适合环境，被保存下来的概率越大，因此在设计适应度函数时将尽可能使目标函数值越大的个体的适应度值越大，而目标函数值越小或者无法满足约束条件的个体适应度越小。然后进行选择操作，为了避免陷入局部最优，在选择过程中采用概率的思想，使用轮盘赌的方式，设置适应度较大的个体被保留的概率更大，适应度较小的个体则被选择的概率很小。保留下来的解（个体）进行繁殖，在繁殖过程中会发生染色体的重组和变异过程，不同解之间的编号进行交叉互换，从而保证解的多样性，当找到比当前目标函数更优的解时更新最优解，如此迭代下去直到最优解的目标值收敛稳定或者已经达到最大的迭代次数，此时就认为已经找到最优解，其算法流程图如下所示。

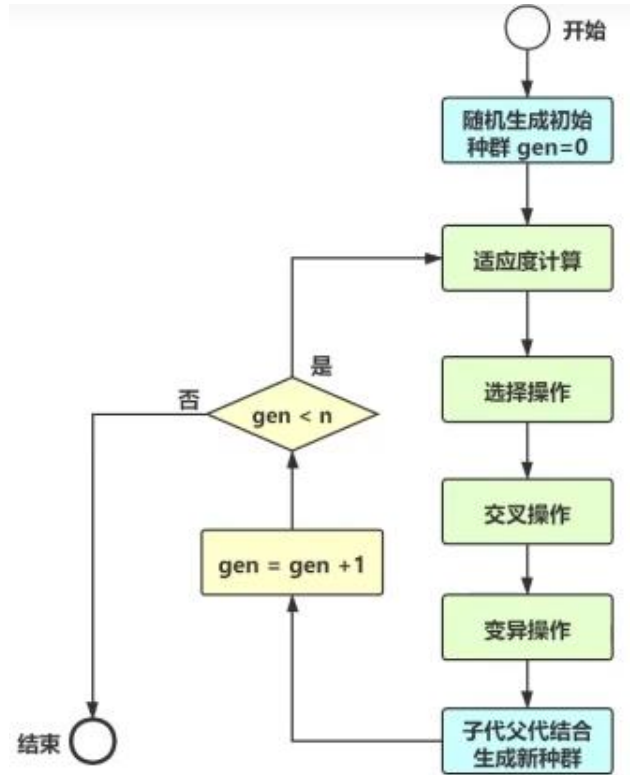


图 4.1 遗传算法工作流程图

### 4.1.2 遗传算法设计

#### (1) 编码解码

在算法开始之前，首先需要对解进行编码，将我们要求计算的解进行编码，以方便进行算法求解。在本研究中，我们对路径直接进行编码，例如按顺序对客户点分别进行编号编为 1、2、3……，从而将一条路径表示为一维列表形式，如[14, 6, 1, 12, 10, 8, 15, 11, 2, 5, 3]表示按照列表中从左往右的顺序依次访问该节点。而一个个体通常包含如上所示的多条路径，因此个体用二维列表表示，种群则包含多个个体，因此种群采用三维列表的数据格式表示。

#### (2) 生成初始种群

首先生成初始种群，为提高初始种群的质量，防止在生成初始种群时出现访问重复节点以及初始种群无法满足车辆载重约束的情况，本研究在设计生成初始种群的函数时，将客户点进行随机打乱，然后以车辆载重约束为约束条件，将客户点依次填入个体中，直到遍历所有客户点，这样生成初始种群虽然可能降低了初始种群的多样性，但防止质量极差的基因片段的出现，使算法可以更快收敛。

#### (3) 插入充电站节点

为进行后续适应度的计算，在生成客户点初始种群后插入充电站节点，插入充电中节点的策略如下所示：

计算到达下一个节点后的剩余电量，计算下一个节点到达最近充电站的所需电量，若到达下一个节点后的剩余电量大于下一个节点到达最近充电站的所需电量，则在下一个节点之前不插入充电站节点；若到达下一个节点后的剩余电量小于下一个节点到达最近充电站的所需电量，则在当前节点搜索最近充电站；若当前剩余电量大于到达距离当前节点最近充电站所需电量，则在当前节点之后插入距离当前节点最近的充电站编号，若当前节点所剩余电量

小于到达充电站所需电量，则在当前节点之前插入距离上一节点最近的充电站节点编号。

#### (4) 适应度计算

对解完成编码后即可进行适应度设计，适应度函数由第二章中建立数学模型时得到的配送成本函数以及约束条件组合而成如下所示：

$$f = \min(C_{\text{成本}} + C_{\text{惩罚}}) \quad (35)$$

其中成本函数的计算如第二章所示，包括充电成本计算，车辆使用成本计算、客户时间窗惩罚成本、充电成本、运输成本。

$$C_{\text{成本}} = \min(C_t + C_k + C_e + C_r) \quad (36)$$

在设计约束条件惩罚函数时，考虑到了车辆载重约束，重复节点约束和访问所有节点约束，当个体中出现，一个路径的所有客户节点的需求量之和大于车辆载货量的极限时，设置惩罚函数的值为无穷大，即  $\text{float}("inf")$ ；当个体中出现，任意一个路径中出现访问重复节点时，设置惩罚函数的值为无穷大，即  $\text{float}("inf")$ ；当个体中出现，遍历所有路径后仍有客户节点未被访问时，设置惩罚函数的值为无穷大，即  $\text{float}("inf")$ 。

当初始解确定后，根据上一步中插入充电站节点策略，即可每个初始解所对应的包含充电站节点的规划路径，根据上式和第二章建立的数学模型进行求解得到每个初始解对应的成本值。依据最小化总利润这一目标设计适应度函数，同时考虑违反约束条件的惩罚，即可定义适应度如下所示：

$$F = [(C_t + C_k + C_e + C_r) + F_{\text{惩罚}}] \quad (37)$$

#### (5) 选择算子

设计选择算子时，我们采用易于实现的轮盘赌选择，计算所有个体的适应度之和，由于在上一步设计适应度时，优化目标设计为最小化适应度的值，因此在计算每个个体的选择概率时，需要先对每个个体计算得到的适应度的值取倒数，除以所有个体的适应度倒数之和。将每个个体的选择概率进行累积，和为 1 得到每个个体所对应的区间。随机生成一个 (0, 1) 之间的数，该数落在哪个个体区间内，则选择该个体。轮盘赌选择的实现过程比较简单，便于理解，但当个体之间适应度值差异很大，选择概率过多集中于某些个体上，则会导致基因流失，个体多样性减少，可能引起早熟，陷入局部最优。

#### (6) 交叉变异算子

交叉变异算子是遗传算法模拟自然选择的关键机制之一，用于迭代生成新的解，设计合适的交叉变异算子可以扩大遗传算法的搜索范围，防止遗传算法提前收敛，提高解的质量。本研究设计交叉变异算子时，采用顺序交叉方法，顺序交叉是一种常用于解决排列问题的算子，它可以保证子代的基因在交叉变换后不会出现重复或缺失，即每个元素只出现一次。首先随机选择交叉区间，将父代的中间段复制到子代，然后按照顺序从另一个父代中选择为出现的元素填充到子代的剩余位置，从而生成新的子代个体。经过测试，这种交叉变换算子虽然避免了产生重复节点或缺失节点的情况，但有时会出现子代与父代基因相同的情况，为了增加算子的搜索范围，本研究在交叉变换算子中检查子代与父代基因是否完全相同，当完全相同时，对子代基因随机的两处位置的基因进行交换位置。

#### (7) 输出结果并迭代

将子代种群中最优的个体（即适应度最低）取出来，并将子代种群变量重新赋值给父代



种群变量即可实现迭代，迭代终止条件设置为，完成固定迭代次数后停止迭代，输出最后一代的种群。

## 4.2 实验对比与分析

### 4.2.1 实验数据准备

本研究所用到的客户点、车站和充电站位置、需求量、载重量、时间窗成本等数据均来自于 Mendeley Data 公开数据集。

由于本研究所需数据集类型较多，范围较广，难以直接获取所需的全部数据。因此在验证优化算法可行性时，我们选择将第三章中所使用的交通流量数据集与 Mendeley 公开数据集进行拼接构造，即认为第三章中所用到的交通流量数据集即为 Mendeley 数据集中点集之间路径的交通流量，这样在第三章中预测得到的一天内的行驶车速可以直接引入本模型中使用。

在进行路径规划时，传统的规划模型通常假设车速是恒值，用路程除以车速得到从点中转移的时间，这显然是不合理的，由于这一不合理的假设会导致计算到达客户点时间时产生误差，进而影响时间窗惩罚成本的计算。虽然现实中车速通常会因为实际道路交通情况而不断发生变化，但在短时间段内通常保持不变，为方便后续进行数值计算（如计算两节点间行驶所需时间时，利用连续变换的车速难以对时间进行求解），在本研究中，我们将采取分段常量函数来描述车辆在道路上的行驶状态，我们认为车辆在道路中 5 分钟之内的行驶速度为恒定，从而能一定程度上减少计算误差，选择 road\_id=1 的道路预测数据进行表示如下图所示。




图 4.2 速度分段函数

如上图所示，其中红色区间表示，当给定两节点之间的行驶路程为 100km，并确定出发时刻时，计算得到的到达下一节点的时刻。由于 Mendeley 数据集中设定的车速为 1 或 2，因此为了能将第三章中预测到的车速数据直接使用，需要对数据进行归一化处理，将原始预测得到的车速数据映射到 (0, 2) 区间上。得到结果如下图所示。




图 4.3 速度分段函数归一化

为方便后续进行对照实验，分别选取了“c103C15”作为小规模数据集，“c101\_21”作为大规模数据集，其中，小规模数据集包含 5 个充电站点和 15 个客户点；大规模数据集包含 21 个充电站点和 100 个客户点。如下图所示为对小规模数据集和大规模数据集的可视化，其中中间红色圆点表示车站即物流配送中心，配送车辆将从车站出发。蓝色三角形节点表示充电站，当车辆到达充电站节点时可以补给电量。绿色正方形节点表示客户节点，配送车辆将依据算法给出的配送方案依次访问这些客户节点完成物流配送服务。




图 4.4 小规模（左图）、大规模（右图）数据集可视化

数据集中对相关成本，数据集是标准化后的数据集，所有相关数据均无量纲设置如下表所示：

表 4-1 相关成本设置

单位路径运输成本	单位充电成本	单位时间窗惩罚成本	车辆使用成本
0.01	1	0.01	100

综上所述，我们已完成数据的准备和预处理工作。

## 4.2.2 考虑精英保留策略的改进遗传算法实验分析

### （一）考虑精英保留策略的算法改进

在 4.1 章节中，我们完成了传统遗传算法设计，在本章节，我们将展示初步实验的结果并根据实验结果对遗传算法进行改进和优化，由于对考虑交通流量下的电动车辆物流配送模

型进行求解所耗费的时间过长，而遗传算法的性能如收敛速度、解的质量只与算法本身的搜索策略有关，不会随数学模型的改变而产生较大差异，因此本章节所使用的模型不考虑交通流量的影响，认为车速始终保持常量不变，同时在充电策略上，采用 100% 充电策略，即车辆到达充电站后在充满电再离开。

使用改进前的遗传算法进行求解，其中迭代次数初设定为  $\text{generation} = 100$ ，种群个数初设定为  $\text{pop\_size} = 50$ ，求解结果如下图所示，其中图 19 中左图、右图分别是使用小规模数据集的适应度变化的曲线和最终的规划的结果，而图 20 中左图、右图分别是使用大规模数据集的适应度变化的曲线和最终的规划的结果。

如下图 20、21 所示，可以证明上述设计的遗传算法具有逐渐收敛寻优的性能，但仍然存在较为明显的问题。首先在适应度变化方面计算结果发生了震荡波动，虽然在小规模的数据集中震荡并不会影响迭代寻找最低值，但在面对大规模数据集的表现上，经过 100 代迭代后，最终结果依旧无法趋于稳定，并且最终寻找到的解并不是所有迭代中的最优解，为了解决这一问题，本研究对上述设计的传统遗传算法进行改进，引入精英保留策略，将父代中的适应度最低（解的质量最优）的个体，直接保留在子代，虽然在一定程度上降低了算法的搜索范围，但可以解决算法求解的适应度变化曲线发生波动的情况。




图 4.5 小规模数据集适应度变化曲线与路径规划方案（算法改进前）

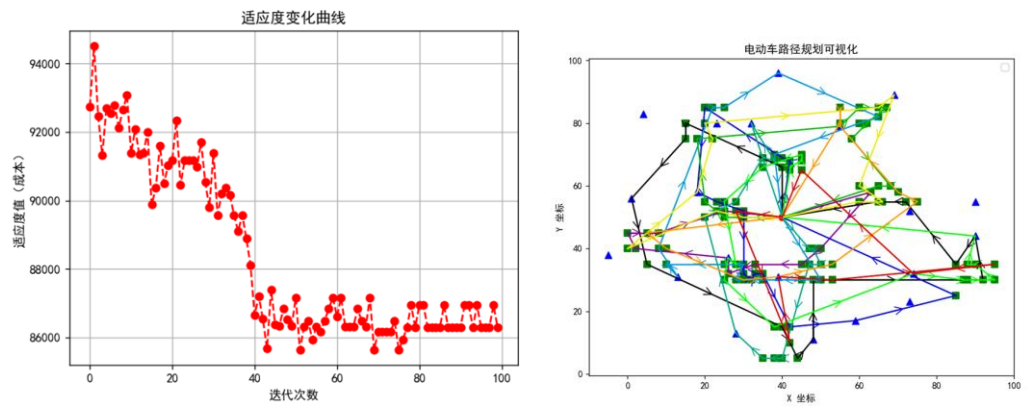


图 4.6 大规模数据集适应度变化曲线与路径规划方案（算法改进前）

如下图 22 所示，为引入精英保留策略后算法的求解结果，从图中可以看出，引入精英保留策略后，算法适应度变化的情况趋于稳定，直到找到更优解时，适应度的值才会发生变化，但算法仍然存在较大问题。解的质量过差，从图 20 右图所示的路径规划方案可以看出，该算法求解的规划结果十分不理想，规划的行驶路径十分复杂且适应度值较高，经过多次测试，适应度的值始终停留在 24000 附近远远超出预期，这说明算法陷入了局部最优的结果，

并且距离最优解的距离较远。为提高最终解的质量，我们考虑利用先验知识引导算法在生成初始种群时，就生成较为靠近理想解的情况。




图 4.7 大规模数据集适应度变化曲线与路径规划方案（精英保留策略）

### （二）改进初始种群生成算子

通过上节中设计的适应度函数我们可以分析，初始种群的质量与路径产生成本成正比，由第二章中建立数学模型我们可以得到路径成本由客户惩罚成本、运输成本、车辆使用成本和充电成本组成，而初始种群为客户访问顺序的二维列表，而客户的访问顺序直接决定了路线行驶路径的长短，而路径行驶路径与运输成本之间呈正比。因此，通过上述分析，我们可以发现，行驶距离较短的规划方案往往适应度较低，解的质量较高，因此在设计生成初始种群的算子时，我们可以考虑生成的个体尽可能路径短。

初始种群生成算子的改进策略如下：首先建立一个车辆行驶路径列表，随机选择一个客户点，将其加入到路径列表中，然后遍历所有客户点集合选择距离该客户点最近的客户点，将其加入到路径列表中，直到达到车辆载重约束即所有用户的需求量大于车辆载重量时，停止搜索退回到上一节点。建立新车辆路径，重复上述操作，直到遍历所有客户节点。这样即可得到一条车辆行驶路径相对较短的初始种群，其成本显然较为理想。




图 4.8 大规模数据集适应度变化曲线与路径规划方案（改进初始种群生成算子）

由上图所示大规模数据集的实验结果最低成本为 1967，实验结果符合预期，我们将解的质量提高了约 92%，经过改进后计算的成本大幅度降低，这说明在路径规划的所有成本来源中，运输成本占主要部分，由于现实物流配送任务中，客户点分布相对集中，呈集群式分布，因此派一辆车去完成一个客户点集群的配送策略可以大大降低车辆行驶距离进而减少物流公司的配送成本。

### （三）遗传算法参数分析

遗传算法的主要参数有种群数量和迭代次数,这两者共同决定了遗传算法的搜索范围和收敛速度。在迭代次数的设置方面,我们认为当随着算法迭代次数增加,若超过 20 代,算法求解的最低适应度值仍然不发生改变,则认为算法已经达到稳定,由于在先前的实验中,我们发现大多数情况下,算法求解可以在 80 代之前达到稳定,为减少算法运行时间,节约算法计算资源,我们在后续的实验中设置迭代次数参数为 80,若后续实验发现 80 次无法满足计算收敛,我们将针对特殊情况对其进行微调。

在种群数量参数的设置方面,种群数量越多虽然理论上搜索范围越大,但当种群数量过多时,不仅会增加计算负担,还会导致在后代进行轮盘赌选择时,最优个体被选择的概率下降,从而降低算法的收敛性;若种群数量设置过低,则降低种群基因的多样性,导致算法过早陷入局部最优。为得到算法表现最优下的初始种群参数值,我们设计了如下所示的对照实验方案。

我们分别将算法种群参数设置为 10、20、30、40、50、60 进行对照实验,即使算法参数相同,由于每次生成初始种群质量不同,每次求解得到的结果依旧可能发生改变,为避免这种不确定性因素的影响,我们将设置所有对照组的初始种群一致,并对每组进行三次实验选择平均值,对照实验结果如下表所示:

表 4-2 对照实验结果

对照组	第一组	第二组	第三组	第四组	第五组	平均解
pop_size = 10	1993	1979	1922	2021	1967	1976.4
pop_size = 20	1968	1948	1978	1951	1977	1964.4
pop_size = 30	1933	1965	1927	1942	1951	1943.6
pop_size = 40	1977	1952	1931	1982	2011	1970.6
pop_size = 50	1997	1951	1964	1933	1968	1962.6
pop_size = 60	1977	1952	1971	1948	1978	1965.2
pop_size = 70	1993	1978	1948	1948	2030	1967.4
pop_size = 100	1979	2011	1987	1951	1979	1981.4

根据上面对照实验结果可知,当初始种群设置值为 30 是在相同初始种群下,算法搜索到的解的质量最高,平均质量可以达到 1943.6,所以在后续实验中将保持初始种群的参数为 30。

### 4.2.3 考虑交通流量下的电动车物流配送遗传算法实验分析

在上面的所有实验中,我们在建立数学模型时默认了车速保持恒速不变,显然这一设定是不合理的,现实场景中,在物流车辆进行配送任务的过程中,难免会遇到交通拥堵等情况,这将无法避免的造成客户,车辆行驶的平均耗电量增加,配送时间延长,进而导致配送过程中的充电成本与时间窗惩罚成本变大。因此,考虑交通流量下的电动车物流配送模型更加贴合现实场景,本节将关于对代码中建立的数学模型进行相应调整,并分别使用小规模数据集和大规模数据集进行实验。

在第三章中我们已经基于历史数据得到了广州市某条道路交通情况的预测数据,由于该



数据集中已经给出了所需要的车辆平均车速数据，因此不必使用公式（3）进行计算，由于无论是小规模客户点或是大规模客户点，若要模拟计算所有道路的交通流量情况，不仅工作量较大，需要的数据集远远超过了所获取的数据集，因此为实验验证算法的可行性与模型的有效性，我们使用部分道路的数据集来模拟所有道路的交通情况，如下图所示为分别针对大规模数据集与小规模数据集采用时变车速数据时计算的到的适应度变化结果图。

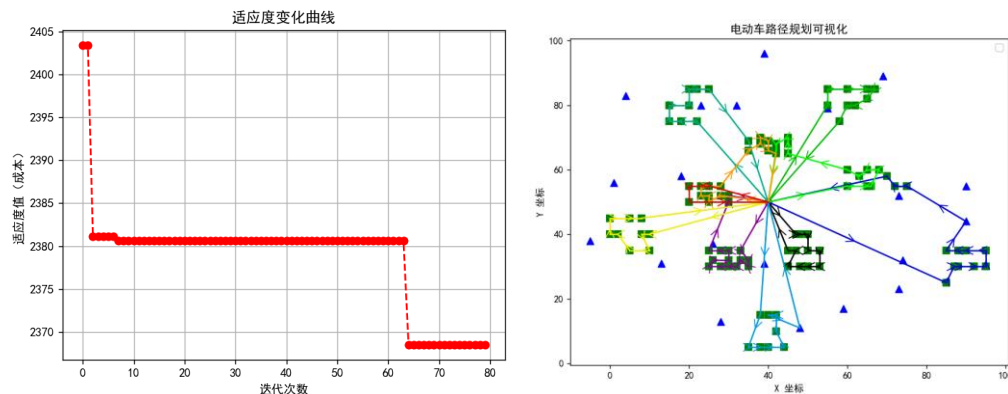


图 4.9 大规模数据集适应度变化曲线与路径规划方案（考虑交通流量影响）

如上图所示，在算法性能相同，输入初始种群相同，使用数据集相同的前提下，考虑交通流量影响的电动车模型的成本与前面实验结果有较为明显的差异，考虑交通流量影响模型计算得到的规划路线的最低成本为 2368，相比使用恒速假设的模型成本提高了 401，提升了约 20.4%。需要注意的是，当考虑交通流量影响时，算法的计算量将大幅度提高，代码运行时间为 1089.5 秒，而恒速模型的代码运行时间为 247.7 秒。

由以上实验可以得到结论，考虑交通流量影响的数学模型相比于假设车速始终保持恒定不变状态的数学模型求解得到的路径规划方案在成本上提升了约 20.4%。因此，交通流量对于车速的影响在建立数学模型时是不可被忽视的因素。

#### 4.2.4 电动车充换电物流配送策略的遗传算法实验分析

在第二章中我们建立了不同充换电策略在不同成本下的数学模型，本节将针对不同充换电策略进行仿真计算，以分析不同充换电策略之间的优劣，由于小规模数据集客户点数量过少，成本普遍较低，为更好的展现不同策略间的差异以下实验均根据上文提到的大规模数据集“c101\_21”进行实验。

在第二章中我们提出了三种不同充换电策略，第一种是 100% 充电策略，其明显特征为当物流配送车辆需要充电时，前往充电站充满电然后离开前往下一个客户点；第二种是 80% 充电策略，由于汽车充电速度非线性影响即当充电量到达电池总容量的 80% 以后充电速度会明显减慢，这导致大部分车主会选择在充到 80% 之后提前离开充电站，虽然补给的电量不一定足够完成剩余行驶任务，但可以减少在充电站浪费的时间，从而躲避顾客的时间窗惩罚；第三种是换电策略，随着换电站的普及，未来将会有更多的新能源汽车采用换电策略补给电量，换电不仅可以保证电池的回收，对于物流配送公司而言，采用换电策略可以进一步加快配送时间降低客户惩罚成本，但同时电池租赁成本远高于充电成本，根据文献显示采取换电的单位电量成本约是充电成本的 3 到 4 倍。

为模拟不同充换电策略之间的差异，对不同策略单独创建了 python 代码文件，通过更改在充电站停留的时间、单位电量的充电成本、离开充电站时的电量三个参数，来刻画这三种充电策略的效果，进而仿真计算每种策略下的求解情况。

表 4-3 针对不同充换电策略的相关参数设置

成本 策略	离开电站时电量	单位充电成本	充电站停留时间
100%充电策略	100	1	90
80%充电策略	80	1	45
换电策略	100	4	0

不同 充换电策略下的仿真求解结果如下图所示：




图 4.10 80%充电策略求解结果图




图 4.11 100%充电策略求解结果图




图 4.12 换电策略求解结果图

如上图所示，80%充电策略求解的规划方案的最低成本值为 3240.26,100%充电策略求解的规划方案的最低成本值为 3247.31，换电策略下求解的规划方案的最低成本值为 2005.28，

显然在本研究采用的大规模数据集展示的场景中，80%充电策略与 100%充电策略对于规划方案的影响并不明显，并且其仿真求解得到的最低成本差异不大，而换电策略下求解的最低成本值则明显低于充电成本。因此，在该数据集所展示的算例中，采取换电策略要更优，相比于充电策略，使用换电策略的规划方案的配送成本降低了约 38.3%。

考虑到当面临不同的场景时，不同策略的表现可能会产生差异，例如，当客户惩罚成本较高时，尽快将物流配送到顾客点的优先度要高于充满电的优先度，而当充电成本较高时，减少充电量在规划时的优先级更高，而当换电成本较高时，换电策略也许就失去了其优势，为了进一步分析不同策略所适用的场景，我们将通过设置不同的成本参数来进一步实验探究，分别设立三种场景。分别是：高充电成本场景、高惩罚成本场景、高换电成本场景，在高充电成本场景中，充电成本是其他场景的 3 倍，而换电成本是充电成本的两倍；在高惩罚成本场景中，时间惩罚成本是其他场景的 3 倍，其他成本保持不变，在高换电成本场景中，换电成本是充电成本的 6 倍。具体不同场景的参数设置如下表所示：

表 4.4 模拟不同场景中的参数设置

成本 场景	充电成本	时间惩罚成本	换电成本	运输成本	车辆使用成本
高充电成本	3	0.03	6	0.01	100
高惩罚成本	1	0.09	4	0.01	100
高换电成本	1	0.03	10	0.01	100
基准场景	1	0.03	4	0.01	100

高充电成本的场景下，不同充电策略的表现如下表所示：

表 4-5 高充电成本的场景下不同策略的表现

充换电策略	80%充电策略	100%充电策略	换电策略
最低成本	4091.3	3752.5	2786.7






图 4.13 高充电成本场景下充换电策略求解结果图

如上图表中结果所示，在若充电成本较高时，采用换电策略常常配送成本最低，此时单位换电成本仅是充电成本的 2 倍，且在充电站补给的时间可以忽略不计，极大的节约了配送时间，减少了顾客惩罚成本，其次是 100%充电策略，成本最高的是 80%充电策略。

高惩罚成本的场景下，不同充电策略的表现如下表所示：

表 4-6 高时间惩罚成本的场景下不同策略的表现

充换电策略	80%充电策略	100%充电策略	换电策略
最低成本	5460.6	5920.6	2487.7

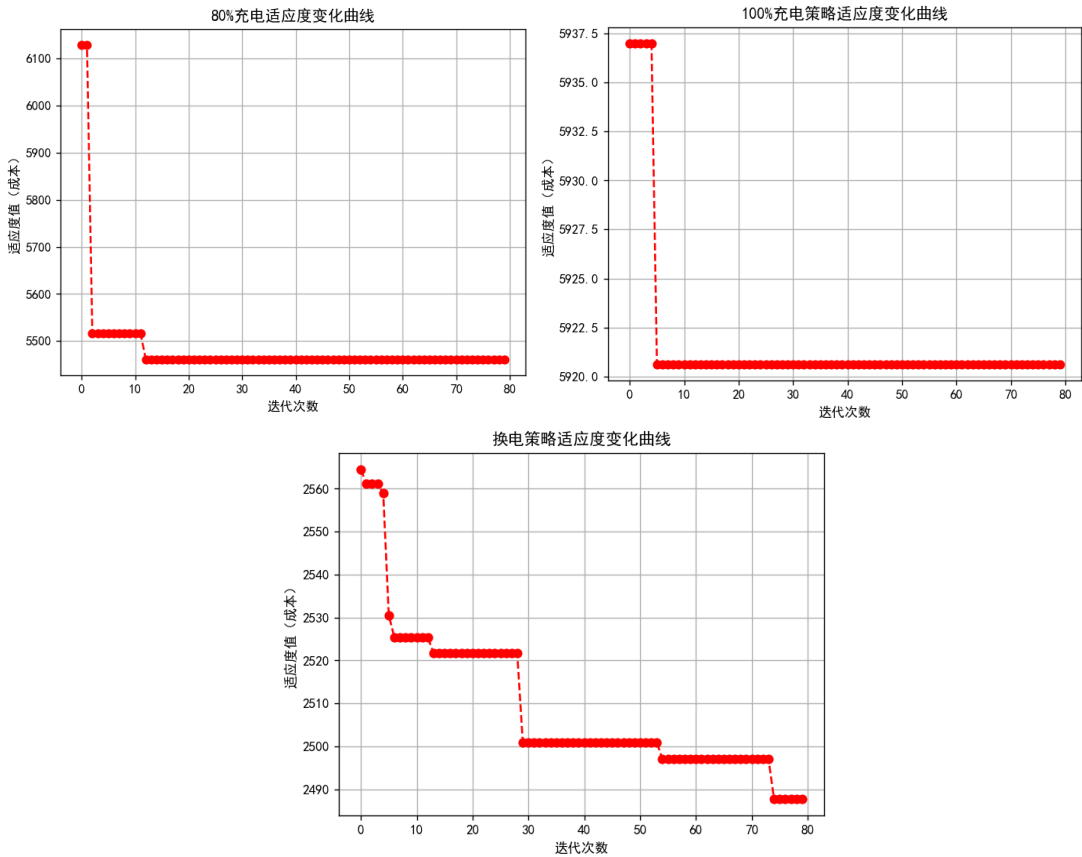


图 4.12 高惩罚成本场景下充换电策略求解结果图

如上图表所示，当面临高惩罚成本场景下，即顾客对配送的时效性要求很高时，此时依然是采取换电策略产生的成本最低，其次是 80%换电策略，最后是 100%充电策略。其中，在采用充电策略时，80%充电策略相比于采用 100%充电策略成本降低了约 8.4%。

高换电成本的场景下，不同充电策略的表现如下表所示：

表 4-7 高换电成本的场景下不同策略的表现

充换电策略	80%充电策略	100%充电策略	换电策略
最低成本	3365.7	3377.5	3473.8

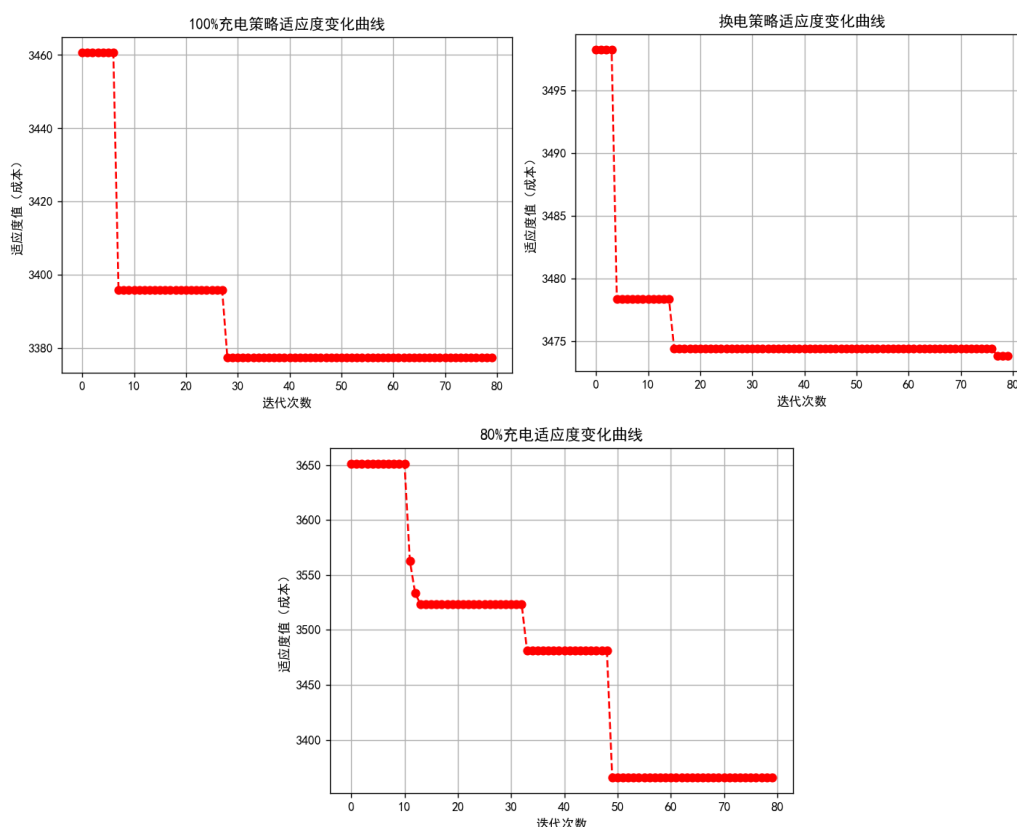


图 4.13 高换电成本场景下充换电策略求解结果图

如上图表所示，当面临高换电成本场景下，即换电成本是充电成本的 10 倍以上时，此时采用充电策略最为划算，采取 80% 充电策略或采取 100% 充电策略影响并不明显。

### 4.3 本章小结

本章我们首先进行了遗传算法的设计，并展示了实验所需的数据集，接着我们进行了三个方面的实验分析。首先针对算法性能，我们分别通过引入精英保留策略、改进初始化种群算子、优化种群规模参数来对算法进行改进和优化，达到了非常理想的效果，计算得到的解的质量相比改进前提高了 90%。紧接着我们针对考虑交通流量影响的数学模型进行了仿真计算，计算成本相比于忽略交通流量的模型提高了 30%，得出结论：交通流量是不可忽视的因素。最后我们针对不同场景，对充换电策略进行对比。

## 第五章 总结与展望

### 5.1 总结

本研究针对传统电动车辆路径规划数学模型中忽略实际道路交通流量影响,车速保持恒定不变的假设进行研究。引入 CEEMD-LSTM 交通流量预测方法获取未来道路交通流量数据,并分析了在现实进行物流配送中,由于道路交通流量的影响车速常常无法稳定在恒定不变的状态,建立了数学模型,最后建立仿真求解算法进行模拟仿真,实验结果证明,在相同数据集中,考虑交通流量影响对比传统数学模型配送成本提高了约 20.4%,这说明道路实际交通流量对于配送方案的影响是不可被忽视的。

最后,在本文提出的考虑交通流量影响的电动车辆路径规划数学模型的基础上,分析了不同充电策略在不同成本场景下的表现,实验结果证明,在换电成本小于充电成本 10 倍以下时,采用换电成本的策略往往最节约成本,而当采取充电策略时,若客户惩罚成本很大,即每单位时间的惩罚成本大于等于单位时间充电成本,则此时采用 80%充电策略更节约成本,若客户单位时间惩罚成本远远小于等于单位时间充电成本,则此时采用 100%充电策略最节约成本。

### 5.2 展望

本文中在第二章建立充换电策略的数学模型时考虑到了充电站的排队等待时长以及电池的使用损耗成本,但是在后续建立求解算法时,由于缺失数据集等因素,无法实现,这也使得本文实际使用的数学模型仍有不足,即忽略了电池使用损耗成本以及充电站的排队时长,这不仅将可能影响整体的规划结果和规划成本,也对后文中的不同充电策略的表现产生一定程度的影响。

在交通流量预测的模型方面,由于该方法在本研究中仅作为获取未来交通流量数据的一种方式,并不属于本研究主要研究对象,因此,本文采用的深度学习方法较为传统。CEEMD-LSTM 模型只能提取交通流量数据中时间维度的特征,而道路交通流量不仅仅存在时间相关性还存在空间相关性,目前较为先进的交通流量预测算法如时空图卷积神经网络模型可以提取交通流量数据中的空间特征和时间特征,因此如何较为准确的获取未来交通流量数据,进而较为准确的预估配送车辆在行驶过程中车速变化情况,对于模型的有效性和准确性具有重要的意义,也是本研究未来的发展方向之一。

## 参考文献

- [1] Dantzig G.B., Ramser J.H.. The truck dispatching problem[J]. Management science, 1959, 6(1): 80-91.
- [2] 张博,周君陶,莫志遥.时变特性下考虑充电排队时间的电动车路径优化[J].交通世界,2023,(15):4-9+13.DOI:10.16248/j.cnki.11-3723/u.2023.15.008.
- [3] 温廷新,李可昕,赵琳琳等.时变路网下电动汽车冷链配送路径规划研究[J].大连理工大学学报,2022,62(06):641-649.
- [4] 王玖河,安聪琢,郭田宇.时变路网下电动冷藏车配送路径优化研究[J].工业工程,2022,25(04):60-69+107.
- [5] 陈秋实.基于交通流预测的电动汽车节能动态路径规划[D].武汉理工大学,2022.DOI:10.27381/d.cnki.gwlg.2022.001629.
- [6] 李可昕. 时变路网下的M生鲜肉类公司电动汽车冷链配送路径优化研究[D].辽宁工程技术大学,2023.DOI:10.27210/d.cnki.glnju.2023.000532.
- [7] 胡婉婉.多事故下城市路网应急车辆路径规划与实时调度研究[D].重庆交通大学,2023.DOI:10.27671/d.cnki.gcjtc.2023.000161.
- [8] 胡凯,袁鹏程,李佑霖.时变路网下考虑碳排放的需求响应型公交调度优化模型[J/OL].计算机应用研究:1-14[2024-02-27].<https://doi.org/10.19734/j.issn.1001-3695.2023.10.0506>.
- [9] 赵佳欣,雷斌,王菀莹.时变网络下多车型同时取送货车辆路径优化[J].计算机工程与设计, 2023,44(10):3096-3102.DOI:10.16208/j.issn1000-7024.2023.10.028.
- [10] 刘文琪.时间依赖型的带软时间窗同时取送货车辆路径优化研究[D].大连海事大学,2019. DOI:10.26989/d.cnki.gdlhu.2019.001069.
- [11] 范厚明,张跃光,田攀俊等.时变路网下异型车辆动态配置与路径优化[J].系统工程理论与实践,2022,42(02):455-470.
- [12] 范厚明,孙秀娜,张跃光等.时变路网下带混合时间窗的车辆路径问题[J].计算机工程与应用,2022,58(16):292-302.
- [13] 雷宇健. 基于充换电选择的电动车辆路径优化及应用研究[D].太原科技大学,2023.DOI:10.27721/d.cnki.gyzjc.2023.000649.
- [14] 邢思远.考虑速度与能量消耗的电动车辆路径规划[J].物流科技,2023,46(21):93-97.DOI:10.13714/j.cnki.1002-3100.2023.21.024.
- [15] KOK A L, HANS E W, SCHUTTEN J M J. Vehicle routing under time-dependent travel times: The impact of congestion avoidance[J]. Computers & Operations Research, 2010,37(12):2051-2060. DOI:10. 1016/j. cor. 2010. 03. 006.

- [16] TAS D, DELLAERT N,VAN WOENSEL T,et al. Vehicle routing problem with stochastic travel times including soft time windows and service costs[J]. Computers & Operations Research,2013,40(1):214-224. DOI:10. 1016/j. cor. 2012. 06. 005.
- [17] ZHENG Y,LING H. Emergency transportation planning under demand uncertainty and time-dependent travel times[J]. Transportation Research Part B:Methodological,2013,55: 144-158. DOI:10. 1016/j. trb. 2013. 06. 004.
- [18] MONTOYA A,GUÉRET C,MENDOZA J E,et al. The electric vehicle routing problem with nonlinear charging function[J] Transportation Research Part B:Methodological,2017,103:87-110. DOI:10. 1016/j. trb. 2017. 02. 004.
- [19] SCHNEIDER M,STENGER A,GOCKE D. The electric vehicle routing problem with time windows and recharging stations[J]. Transportation Science,2014,48(4):500-520. DOI:10. 1287/trsc. 2013. 0490.
- [20] KEISUKE M. Hybrid fleet routing with electric and diesel vehicles under energy constraints[J]. Transportation Research Part E:Logistics and Transportation Review,2016,94: 80-94. DOI:10. 1016/j. tre. 2016. 07. 006.
- [21] SCHIFFER M,WALTHER G. The electric location routing problem with time windows and partial recharging[J]. European Journal of Operational Research,2017,260(3):995-1013. DOI:10. 1016/j. ejor. 2017. 01. 011.
- [22] ÇATAY B,KESKIN M. Electric vehicle routing problem with mobile charging stations and time windows[J]. Transportation Research Part E:Logistics and Transportation Review,2020(144):102123. DOI:10. 1016/j. tre. 2020. 102123.
- [23] COMERT S E,YAZGAN H R,YILMAZ A,et al. Multi-objective electric vehicle routing problem with time windows and partial recharge[J]. Journal of Cleaner Production,2018(203):646-658. DOI:10. 1016/j. jclepro. 2018. 08. 235.
- [24] VERMA A. Electric vehicle routing problem with fast charging and battery swapping options:A comparative analysis[J]. Energy,2018(158):820-829. DOI:10. 1016/j. energy. 2018. 06. 041.
- [25] HIERMANN G,PUCHINGER J ROPKE S,et al. The electric fleet size and mix vehicle routing problem with time windows and recharging stations[J]. European Journal of Operational Research,2016(252):995-1018.
- [26] KESKIN M ÇATAY B Partial recharge strategies for the electric vehicle routing problem with time windows and fast chargers[J] Computers & Operations Research ,2018(100):172-188.
- [27] DESAULNIERS G ERRICO F IRNICH S et al Exact algorithms for electric vehicle routing problems with time windows and charging stations under linear charging function

- ons[R] CIRRELT Technical Report ,2016.
- [28] FELIPE A ORTUÑO M RIGHINI G A heuristic approach for the green vehicle routing problem with multiple technologies and partial recharges[J] Transportation Research Part E ,2014.
- [29] SHAO S GUAN W RAN B Hybrid genetic algorithm for electric vehicle routing problem with nonlinear charging[J] IEEE Transactions on Intelligent Transportation Systems ,2020.
- [30] CORTÉS-MURCIA D PRODHON C AFSAR H The electric vehicle routing problem with time windows and partial recharge[J] Transportation Research Part E ,2019.
- [31] MACRINA G LAPORTE G DI PUGLIA PUGLIESE L The green vehicle routing problem with accelerated nonlinear charging[J] Transportation Research Part B ,2020.
- [32] KANCHARLA S RAMADURAI G Electric vehicle routing problem with nonlinear charging and load-dependent discharging[J] Expert Systems with Applications ,2020.
- [33] 叶得学 ISSA-SVR模型的短期交通流预测方法研究[J]交通运输系统工程与信息 ,2021.
- [34] 黄艳国改进花朵授粉算法优化的BP神经网络短期交通流预测[J]计算机应用研究 ,2020.
- [35] 张萌LSTM神经网络在短期交通量预测中的应用[J]公路交通科技 ,2021.
- [36] 邹正标GCN与注意力机制结合的时空交通流预测[J]自动化学报 ,2022.
- [37] 曹威Transformer在长期交通流建模中的应用[J]交通运输工程学报 ,2021.
- [38] MENG X,et al ScR-DTG:A deep learning model for traffic volume prediction[J] IEEE Transactions on ITS ,2021.
- [39] HU J,et al BWCL:A hybrid Butterworth-CNN-LSTM model for traffic flow forecasting [J] Transportation Research Part C ,2020.
- [40] CAO H Rolling prediction of short-term traffic flow using BP neural networks[J] Journal of Advanced Transportation ,2019.
- [41] TIAN R Time series combined BP neural network for traffic speed prediction[J] Sensors ,2021.
- [42] LIN Y LSTM-based toll station traffic flow prediction[J] IEEE Access ,2020.
- [43] REZA S Multi-attention Transformer for traffic forecasting[J] Expert Systems with Applications ,2022.
- [44] YAN X Hierarchical Transformer for spatiotemporal traffic flow learning[J] Neural Networks ,2021.
- [45] XU M STTN:Spatiotemporal Transformer network for traffic prediction[J] Knowledge-Based Systems ,2022.
- [46] Ángel Felipe,M. Teresa Ortuño,Giovanni Righini等.A heuristic approach for the green vehicle routing problem with multiple technologies and partial recharges[J].Transportation Research Part E ,2014.

- on Research Part E,2014,71111-128.
- [47] Shao S ,Guan W ,Bi J .Electric vehicle-routing problem with charging demands and energy consumption[J].IET Intelligent Transport Systems,2018,12(3):202-212.
- [48] Cortés-Murcia L D ,Prodhon C ,Afsar M H .The electric vehicle routing problem with time windows, partial recharges and satellite customers[J].Transportation Research Part E,2019,130184-206.
- [49] Macrina G ,Laporte G ,Guerriero F , et al.An energy-efficient green-vehicle routing problem with mixed vehicle fleet, partial battery recharging and time windows[J].European Journal of Operational Research,2019,276(3):971-982.
- [50] Kancharla R S ,Ramadurai G .An Adaptive Large Neighborhood Search Approach for Electric Vehicle Routing with Load-Dependent Energy Consumption[J].Transportation in Developing Economies,2018,4(2):1-9.
- [51] Kancharla R S ,Ramadurai G .Electric vehicle routing problem with non-linear charging and load-dependent discharging[J].Expert Systems With Applications,2020,160

## 附录

表 1 小规模数据集

StringID	Type	x	y	demand	ReadyTime	DueDate	ServiceTime
D0	d	40	50	0	0	1236	0
S0	f	40	50	0	0	1236	0
S3	f	57	82	0	0	1236	0
S7	f	21	83	0	0	1236	0
S13	f	22	34	0	0	1236	0
S15	f	39	26	0	0	1236	0
C61	c	50	30	10	980	1064	90
C30	c	20	55	10	0	1125	90
C98	c	58	75	20	0	1115	90
C59	c	38	15	10	66	124	90
C35	c	5	35	10	655	725	90
C13	c	22	75	30	1042	1106	90
C10	c	35	66	10	779	845	90
C44	c	32	30	10	0	1124	90
C50	c	26	32	10	0	1123	90
C95	c	62	80	30	0	1108	90
C18	c	15	75	20	0	1110	90
C33	c	8	40	40	355	437	90
C85	c	68	60	30	0	1116	90
C19	c	15	80	10	455	513	90
C40	c	35	30	10	143	199	90

表 2 大规模数据集

StringID	Type	x	y	demand	ReadyTime	DueDate	ServiceTime
D0	d	40	50	0	0	1236	0
S0	f	40	50	0	0	1236	0
S1	f	73	52	0	0	1236	0
S2	f	90	55	0	0	1236	0
S3	f	55	79	0	0	1236	0
S4	f	69	89	0	0	1236	0
S5	f	32	80	0	0	1236	0
S6	f	39	96	0	0	1236	0
S7	f	23	80	0	0	1236	0
S8	f	4	83	0	0	1236	0
S9	f	18	58	0	0	1236	0
S10	f	1	56	0	0	1236	0
S11	f	13	31	0	0	1236	0



S12	f	-5	38	0	0	1236	0
S13	f	26	37	0	0	1236	0
S14	f	28	13	0	0	1236	0
S15	f	39	31	0	0	1236	0
S16	f	48	11	0	0	1236	0
S17	f	59	17	0	0	1236	0
S18	f	73	23	0	0	1236	0
S19	f	74	32	0	0	1236	0
S20	f	90	44	0	0	1236	0
C1	c	45	68	10	78	140	90
C2	c	45	70	30	499	553	90
C3	c	42	66	10	863	931	90
C4	c	42	68	10	584	656	90
C5	c	42	65	10	950	1026	90
C6	c	40	69	20	683	741	90
C7	c	40	66	20	774	836	90
C8	c	38	68	20	1057	1125	90
C9	c	38	70	10	958	1040	90
C10	c	35	66	10	779	845	90
C11	c	35	69	10	869	941	90
C12	c	25	85	20	176	228	90
C13	c	22	75	30	1042	1106	90
C14	c	22	85	10	263	327	90
C15	c	20	80	40	745	789	90
C16	c	20	85	40	358	416	90
C17	c	18	75	20	633	711	90
C18	c	15	75	20	557	601	90
C19	c	15	80	10	455	513	90
C20	c	30	50	10	10	70	90
C21	c	30	52	20	11	73	90
C22	c	28	52	20	73	131	90
C23	c	28	55	10	13	70	90
C24	c	25	50	10	72	138	90
C25	c	25	52	40	158	232	90
C26	c	25	55	10	672	744	90
C27	c	23	52	10	263	311	90
C28	c	23	55	20	438	510	90
C29	c	20	50	10	174	226	90
C30	c	20	55	10	355	407	90
C31	c	10	35	20	467	517	90
C32	c	10	40	30	271	337	90
C33	c	8	40	40	355	437	90
C34	c	8	45	20	194	244	90
C35	c	5	35	10	655	725	90

C36	c	5	45	10	278	346	90
C37	c	2	40	20	569	619	90
C38	c	0	40	30	472	532	90
C39	c	0	45	20	374	440	90
C40	c	35	30	10	143	199	90
C41	c	35	32	10	49	109	90
C42	c	33	32	20	239	289	90
C43	c	33	35	10	789	849	90
C44	c	32	30	10	325	387	90
C45	c	30	30	10	421	475	90
C46	c	30	32	30	601	665	90
C47	c	30	35	10	698	754	90
C48	c	28	30	10	511	569	90
C49	c	28	35	10	1011	1073	90
C50	c	26	32	10	923	975	90
C51	c	25	30	10	823	889	90
C52	c	25	35	10	1042	1102	90
C53	c	44	5	20	437	511	90
C54	c	42	10	40	810	868	90
C55	c	42	15	10	905	963	90
C56	c	40	5	30	350	410	90
C57	c	40	15	40	989	1063	90
C58	c	38	5	30	256	320	90
C59	c	38	15	10	66	124	90
C60	c	35	5	20	167	223	90
C61	c	50	30	10	980	1064	90
C62	c	50	35	20	169	229	90
C63	c	50	40	50	15	85	90
C64	c	48	30	10	263	325	90
C65	c	48	40	10	67	139	90
C66	c	47	35	10	1068	1129	90
C67	c	47	40	10	13	88	90
C68	c	45	30	10	354	420	90
C69	c	45	35	10	448	516	90
C70	c	95	30	30	390	444	90
C71	c	95	35	20	481	543	90
C72	c	53	30	10	904	954	90
C73	c	92	30	10	287	361	90
C74	c	53	35	50	78	142	90
C75	c	45	65	20	16	91	90
C76	c	90	35	10	575	639	90
C77	c	88	30	10	534	600	90
C78	c	88	35	20	667	731	90
C79	c	87	30	10	446	506	90

C80	c	85	25	10	637	689	90
C81	c	85	35	30	761	823	90
C82	c	75	55	20	459	529	90
C83	c	72	55	10	556	618	90
C84	c	70	58	20	650	710	90
C85	c	68	60	30	737	809	90
C86	c	66	55	10	173	241	90
C87	c	65	55	20	87	145	90
C88	c	65	60	30	837	895	90
C89	c	63	58	10	929	989	90
C90	c	60	55	10	21	84	90
C91	c	60	60	10	1010	1096	90
C92	c	67	85	20	459	519	90
C93	c	65	85	40	546	616	90
C94	c	65	82	10	367	423	90
C95	c	62	80	30	274	330	90
C96	c	60	80	10	177	243	90
C97	c	60	85	30	645	707	90
C98	c	58	75	20	181	247	90
C99	c	55	80	10	836	896	90
C100	c	55	85	20	744	798	90

## 致 谢

感谢王澍老师在本人毕业论文研究过程中的耐心指导，感谢未来交通学院全体老师、以及所有任课老师四年以来的用心培养，感谢四年大学生活中结识的所有同学，感谢我的家人、朋友。